


Faculté  
des Sciences  
& Techniques



Université  
de Limoges

Master 1<sup>ère</sup> année



Développement GPGPU



P-F. Bonnefoi

Version du 27 octobre 2021

## Table des matières

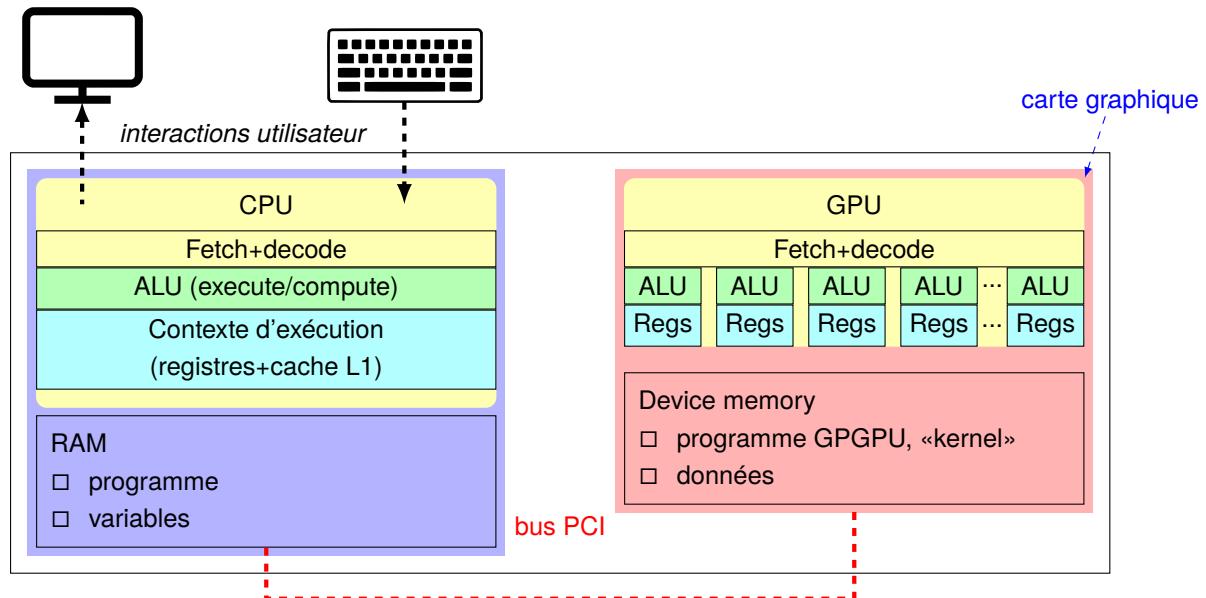
1	CUDA est un modèle SIMD .....	3
	L'architecture CUDA, « <i>Compute Unified Device Architecture</i> » .....	6
	Comment programmer ? .....	8
	Comment est gérer la mémoire ? .....	9
	Comment déclencher le travail sur le GPU ? .....	11
2	CUDA, « <i>Compute Unified Device Architecture</i> » .....	13
	La hiérarchie mémoire .....	15
	Répartition du travail entre threads regroupées en bloc .....	16
	Un seul programme source mixte CPU/GPU .....	18
	Communication entre «l'hôte» et le « <i>CUDA device</i> » .....	20
	Exécution d'une application parallèle sur le « <i>device</i> » .....	22
3	La notion de divergence .....	31
	Comparaison de performance divergence/pas de divergence .....	32
	Synchronisation & Communication .....	35
4	Aggrégation, « <i>coalescence</i> », des accès mémoire .....	38
	Optimisation de la vitesse en localisant mieux les données .....	44
	Stratégie de développement .....	49
	Extraction du parallélisme de données et la définition de «grille» .....	84
	Optimisation .....	86



# 1 CUDA est un modèle SIMD

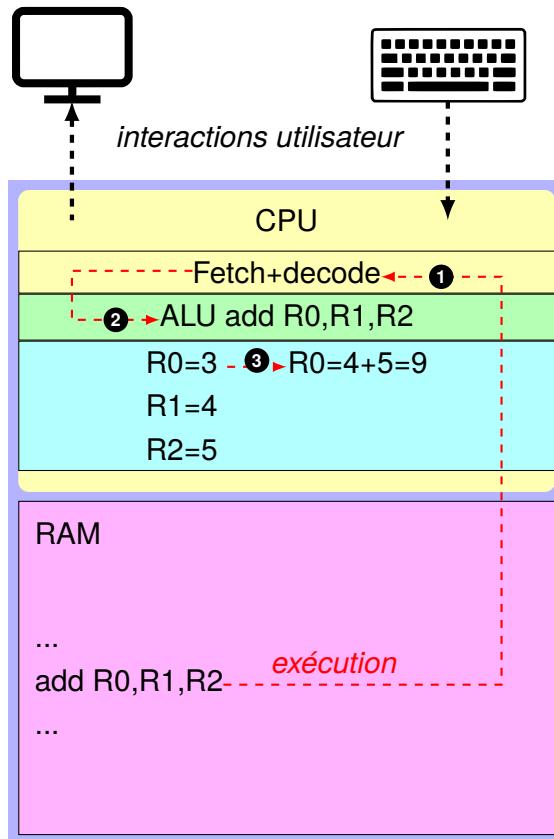
3

- Le CPU est composé de :
- une unité de contrôle chargée de :
    - ◊ chercher en mémoire les instructions à exécuter, «*fetch*» ;
    - ◊ décoder ces instructions en termes d'opération à faire sur les registres et la mémoire ;
  - une unité ALU, «*Arithmétique et Logique*» ;
  - des registres et de la mémoire cache pour limiter les accès à la RAM ;



- Le GPU est composé de :
- une unité de contrôle ;
  - nombreuses unités ALU+Registres combinées (plusieurs milliers).






Déroulement de l'exécution d'une instruction sur le CPU :

- ① ⇒ une instruction est récupérée depuis la RAM et décodée ;
- ② ⇒ elle déclenche des opérations de l'ALU sur les registres et/ou le contenu de la mémoire ;
- ③ ⇒ le résultat est rangé dans un registre ;
- ④ ⇒ on recommence sur l'instruction suivante.



# L'exécution sur le GPU

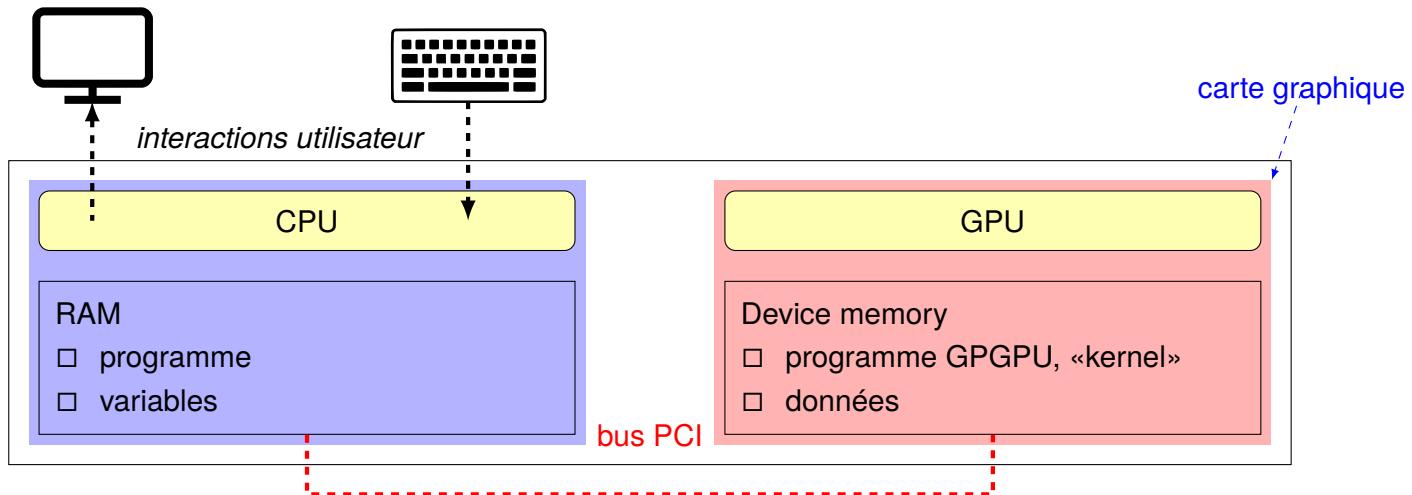
5



Déroulement de l'exécution d'une instruction sur le GPU :

- ①⇒une instruction est récupérée depuis la RAM et décodée ;
- ②⇒elle déclenche des opérations identiques sur les différentes ALU entre les registres associés et/ou le contenu de la mémoire ;
- ③⇒le résultat est rangé dans un registre local.





Architecture CUDA : le système «host», CPU, et le système GPU, la carte graphique sont **séparés** :

▷ la RAM ou la mémoire de l'hôte est accessible uniquement par le CPU ;

▷ la «Device Memory» est accessible uniquement par le GPU ;

⇒ les **données** conservées dans la RAM ou la «*memory device*» doivent être **échangées** entre les deux à l'aide du bus PCI en mode DMA ;

⇒ un **programme** qui utilise le GPU est constitué de deux parties :

- ◊ une partie tournant sur le **CPU**, c-à-d sur l'hôte ;
- ◊ une partie tournant sur le **GPU**, c-à-d sur le «*device*».




# Comment faire travailler le GPU sur les données ?

7


CUDA met à disposition des fonctions de transfert de données entre la mémoire RAM et la mémoire du «device» :

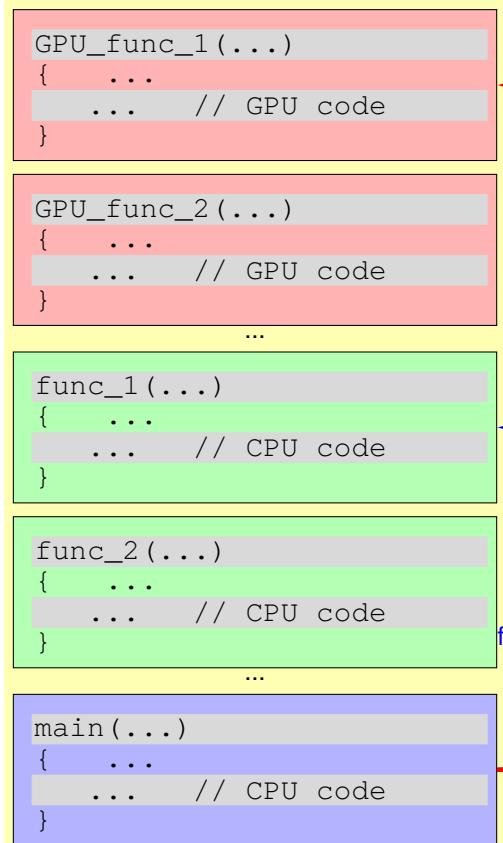
De la RAM vers la mémoire du «device» :

*Des signaux de contrôle sont utilisés par le CPU pour déclencher l'opération sur le GPU.*



De la mémoire du «device» vers la RAM :





⇒ une fonction GPU ne retourne pas de valeur !

Le programmeur écrit **un seul programme source** constitué de deux types de fonctions :

- ▷ les fonctions `func_x` sont exécutées par le CPU comme des fonctions ordinaires ;
- ▷ les fonctions `GPU_func_x` sont exécutées par le GPU sur la carte graphique ;
- ▷ la fonction principale, `main`, exécutée par le CPU appelle les différents types de fonctions : c'est elle qui est appelée en premier au lancement du programme.

Il existe **deux types de fonction GPU** en CUDA :

- ▷ précédées par `__global__` : peuvent être appelées par le «*host*» ou par une autre fonction du «*device*» ;
 

```
__global__ void GPU_function1 ( parameters) {...}
```
- ▷ précédées par `__device__` : ne peuvent être appelées que par une autre fonction du «*device*»
 

```
__device__ void GPU_function2 ( parameters) {...}
```

**Les deux types de fonctions `__global__` et `__device__` ne doivent rien renvoyer (`void`).**



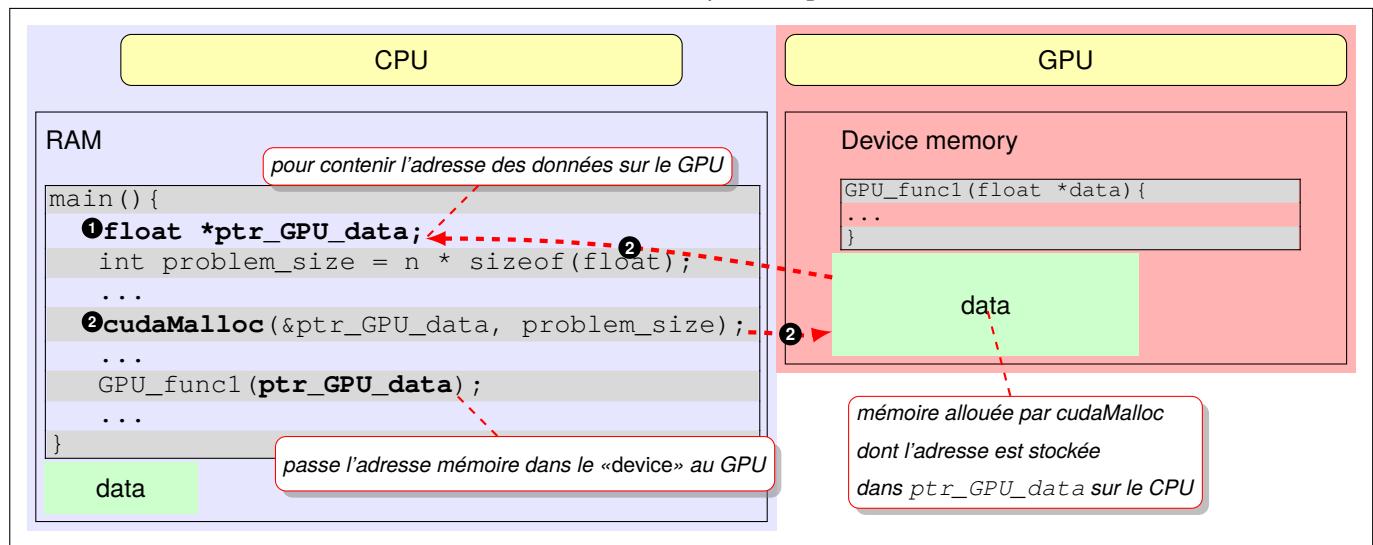
## Comment est gérer la mémoire ?

9

Le «device» ne dispose pas d'OS, «Operating System» : il ne sait pas gérer sa mémoire !

⇒ C'est le «host» qui gère la mémoire pour le GPU :

- ▷ il déclare une variable du type pointeur sur le type de données à manipuler type \*ptr ①;
- ▷ il alloue de la mémoire sur le GPU grâce à la fonction cudaMalloc (&ptr, nombre\_octets) ②:
  - de la mémoire est «réservée» sur le GPU (c'est le CPU qui contrôle les espaces mémoires du device);
  - l'adresse de cette zone mémoire est stockée dans le pointeur ptr;



- ▷ lors de l'appel de la fonction GPU\_func1, le CPU transmettra en paramètre l'adresse de la zone mémoire allouée précédemment stockée dans ptr à la fonction.

⇒ la fonction GPU GPU\_func1 peut travailler sur la zone mémoire du device réservée à cet usage.




## Comment déclencher le travail entre le CPU et le GPU ?


10

L'utilisateur n'interagit uniquement avec le programme CPU :  
⇒ les données sont **unique-  
ment** dans la RAM accessible par le CPU.

⇒ l'appel de la fonction GPU `GPU_func1()` ne peut être fait directement.


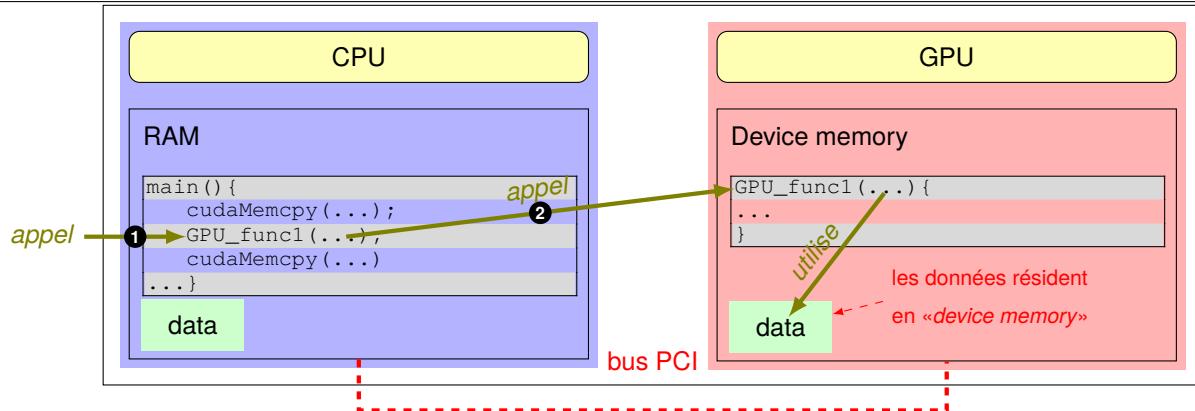


Les données sont transférées du CPU vers la mémoire «device» grâce à une opération `cudaMemcpy()` : les données sont transférées au travers du bus PCI.




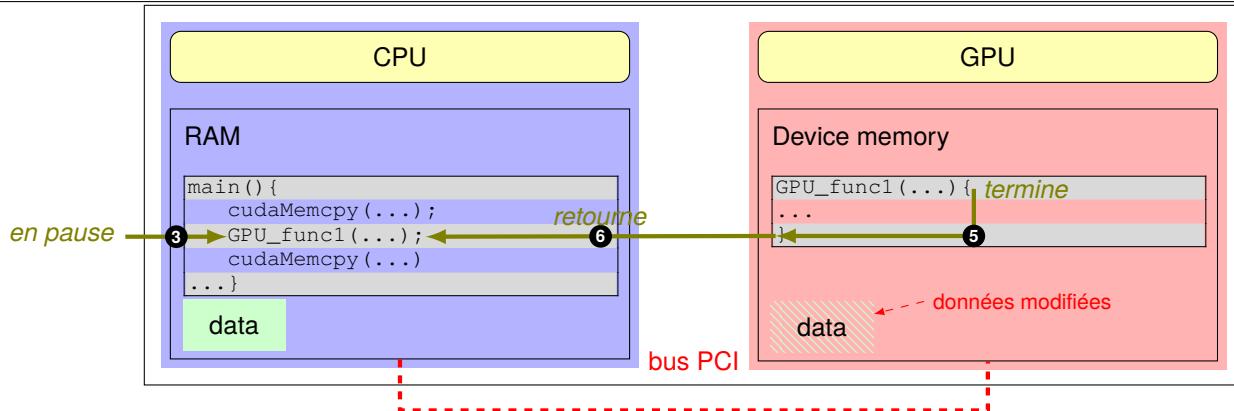
# Comment déclencher le travail sur le GPU ?

11



# Comment déclencher le travail sur le GPU ?

12



C'est un **environnement logiciel** qui permet d'utiliser le GPU, «*Graphics Processing Unit*» au travers de programme de haut niveau comme le C ou le C++ :

- ◊ le programmeur écrit un programme C avec des extensions CUDA, de la même manière qu'un programme OpenMP ;
- ◊ CUDA nécessite une carte graphique équipée d'un processeur NVIDIA de type Fermi, GeForce 8XXX/Tesla/Quadro, etc.
- ◊ les fichiers source doivent être compilés avec le compilateur C CUDA, NVCC.

Un **programme CUDA** utilise des «*kernels*» pour traiter des «*data streams*», ou «flux de données».

*Ces flux de données peuvent être par exemple, des vecteurs de nombres flottants, ou des ensembles de frames pour du traitement vidéo.*

Un «*kernel*» est exécuté dans le GPU en utilisant des threads exécutées en parallèles.

CUDA fournit **3 mécanismes** pour paralléliser un programme :

- ◊ un **regroupement hiérarchique** des threads ;
- ◊ des **mémoires partagées** ;
- ◊ des **barrières de synchronisation**.

*Ces mécanismes fournissent du parallélisme à **grain fin** imbriqué dans du parallélisme à **gros grain**.*



## Des définitions

Terme	Définition
Host ou CPU	c'est l'ordinateur qui sert d'interface avec l'utilisateur et qui contrôle le «device» utilisé pour exécuter les parties de calcul intensif basé sur un parallélisme de données. <i>L'hôte est responsable de l'exécution des parties séquentielles de l'application.</i>
GPU	est le processeur graphique, « <i>General-Purpose Graphics Processor Unit</i> », pouvant réaliser du travail générique qui peut être utilisé pour implémenter des algorithmes parallèles.
Device	est le GPU connecté à «l'hôte» et qui va exécuter les parties de calcul intensif basé sur un parallélisme de données. <i>Le device, ou périphérique, est responsable de l'exécution de la partie parallèle de l'application.</i>
kernel	est une fonction qui peut être appelée depuis «l'hôte» et qui est exécutée en parallèle sur le «device» CUDA par de nombreuses threads.

- \* Le «kernel» est exécuté simultanément par des milliers de threads.

- \* Une application ou une fonction de bibliothèque consiste en un ou plusieurs kernels.

*Fermi peut exécuter différents kernels à la fois, s'ils appartiennent tous à la même application.*

- \* Un kernel peut être écrit en C avec des annotations pour exprimer le parallélisme :


- ◊ localisation des variables ;

- ◊ utilisation d'opération de synchronisation fournie par l'environnement CUDA.





## La hiérarchie mémoire

15



La hiérarchie de mémoire et de threads est la suivante :

1. la **thread** au niveau le plus bas de la hiérarchie ;
2. le **bloc** composé de plusieurs threads exécutées de manière concurrente ;
3. la **grille** composée de plusieurs blocs de threads exécutés de manière concurrente ;
4. de la **mémoire locale** dédiée à chaque thread, *per-thread local memory*, visible uniquement depuis la thread (cela concerne également des registres) ;  
*Les registres sont sur le processeur et disposent de temps d'accès très rapide.*  
*La mémoire locale, indiquée en gris sur le schéma, dispose d'un temps d'accès plus lent que celui des registres.*
5. de la **mémoire partagée** associée à chaque bloc visible, *per-block shared memory*, uniquement par toutes les threads du bloc ;  
*Le bloc dispose de sa propre mémoire partagée et privée pour permettre des communications inter-thread rapides et de taille réglable.*
6. de la **mémoire globale**, «*per-device global memory*», utilisable par le «*device*».  
*Une grille, «grid», utilise la mémoire globale. Cette mémoire globale permet de communiquer avec la mémoire de l'hôte et sert de lien de communication entre l'hôte et le GPGPU.*



## Grille & Bloc : organisation et localisation d'une thread

Le programmeur doit spécifier le nombre de threads dans un bloc et le nombre de blocs dans une grille.

Le nombre de blocs dans la grille est spécifié par la variable `gridDim`.

### Exemple : un tableau à une seule dimension

- ◊ on peut organiser les blocs en un tableau à une seule dimension, et le nombre de blocs sera :

$$\text{gridDim.x} = k$$


ainsi si  $k = 10$ , alors on aura 10 blocs dans la grille.

- ◊ on peut organiser les threads en un tableau à une seule dimension de  $m$  threads par bloc :

$$\text{blockDim.x} = m$$

- ◊ chaque bloc dispose d'un identifiant unique, «ID», appelé `blockIdx` qui est compris dans l'intervalle :

$$0 \leq \text{blockIdx} \leq \text{gridDim}$$



Pour associer une thread à la  $i^{\text{ème}}$  case d'un vecteur, on doit trouver à quel bloc appartient la thread et ensuite la localisation de la thread dans le bloc:  $i = \text{blockIdx.x} \times \text{blockDim.x} + \text{threadIdx.x}$

### Généralisation du concept de Grille et de blocs

- ◊ Les variables `gridDim` et `blockIdx` sont définies automatiquement et sont de type `dim3`.
- ◊ Les blocs dans la grille peuvent être organisés suivant une, deux ou trois dimensions.
- ◊ Chaque dimension est accédée par la notation `blockIdx.x`, `blockIdx.y` et `blockIdx.z`.

La commande CUDA suivante définit le nombre de blocs dans les dimensions  $x$ ,  $y$  et  $z$ :

```
dim3 dimGrid(4, 8, 1);
```

Cette commande définit 32 blocs organisés en un tableau à deux dimensions avec 4 lignes de 8 colonnes.

Le nombre de threads dans un bloc est défini par la variable `blockDim`.



Chaque thread dispose d'un identifiant unique, «ID», appelé `threadIdx` qui est compris dans l'intervalle :

$$0 \leq \text{threadId} \leq \text{blockDim}$$

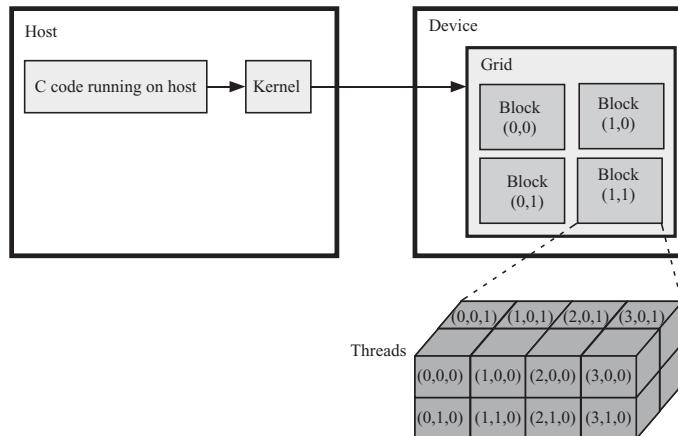
- ◊ Les variables `blockDim` et `threadIdx` sont définies automatiquement et sont de type `dim3`.
- ◊ Les threads dont un bloc peuvent être organisés suivant une, deux ou trois dimensions.
- ◊ Chaque dimension est accédée par la notation `threadIdx.x`, `threadIdx.y` et `threadIdx.z`.

La commande CUDA suivante définit le nombre de threads dans les dimensions  $x$ ,  $y$  et  $z$ :

```
dim3 dimBlock(100, 1, 1);
```

Cette commande définit 100 threads organisées en un tableau de 100 cases.

### Rapport entre «kernel» et grille



- ◊ Chaque «kernel» est associé avec une grille dans le «device».
- ◊ le choix du nombre de threads et de blocs est conditionné par la nature de l'application et la nature des données à traiter.

*Le but est d'offrir au programmeur des moyens d'organiser les threads de manière adaptée à l'organisation des données, afin de simplifier l'accès à ces données : «les données sont organisées en grille ? alors les threads aussi».*




## Un seul programme source mixte CPU/GPU

18

Le code source «*mon\_prog.cu*» est compilé en deux parties :

- un code pour le CPU en instructions x86/amd64 ;
- un code pour le GPU en instructions PTX, «*Parallel Thread eXecution*» ;



Le compilateur *nvcc* fourni par NVidia :

- ▷ réalise la répartition des codes à partir d'un fichier source unique ;
- ▷ compile chaque partie indépendamment ;
- ▷ construit un exécutable contenant les deux parties et capable de charger le code GPU sur le «*device*».



Pour définir une fonction qui va être exécutée en tant que «kernel», le programmeur modifie le code C du prototype de la fonction en plaçant le mot clé «`__global__`» devant ce prototype :

```
__global__ void kernel_function_name(function_argument_list);
```

*La fonction doit renvoyer void.*

Le programmeur doit ensuite indiquer au compilateur C NVIDIA, nvcc, de lancer le «kernel» pour être exécuté sur le «device» :

```
int main()
{
/*
    Une partie séquentielle du code
*/
/* Le début de la partie parallèle du code */

kernel_function_name<<< gridDim, blockDim >>> (function_argument_list);

/* La fin de la partie parallèle */

/*
    Une partie séquentielle du code
*/
}
```

*Le programmeur modifie le code C en spécifiant la structure des blocs dans la grille et la structure des threads dans un bloc en ajoutant la déclaration `<<<gridDim, blockDim>>>` entre le nom de la fonction et la liste des arguments de la fonction.*




- ▷ L'ordinateur hôte dispose de sa propre hiérarchie de mémoire de même que le «*device*».
- ▷ L'échange de données entre l'hôte et le «*device*» est réalisé en copiant des données entre la DRAM, «dynamic ram», et la mémoire DRAM globale du «*device*».
- ▷ De la même façon qu'en C, le programmeur doit allouer de la mémoire dans la mémoire globale du «*device*» pour les données et libérer cette mémoire une fois l'application terminée.

Les **appels systèmes CUDA** suivants permettent de réaliser ces opérations :

Fonction	Description
cudaDeviceSynchronize ()	bloque jusqu'à ce que le « <i>device</i> » ait terminé les tâches demandées précédemment
cudaThreadSynchronize ()	<i>version précédente de cudaDeviceSynchronize ()</i>
cudaChooseDevice ()	retourne le « <i>device</i> » qui correspond aux propriétés spécifiées
cudaGetDevice ()	retourne le « <i>device</i> » utilisé actuellement
cudaGetDeviceCount ()	retourne le nombre de « <i>device</i> » capable de faire du GPGPU
cudaGetDeviceProperties ()	retourne les informations concernant le « <i>device</i> »
cudaMalloc ()	alloue un objet dans la mémoire globale du « <i>device</i> ». Nécessite deux arguments : l'adresse d'un pointeur qui recevra l'adresse de l'objet, et la taille de l'objet
cudaFree ()	libère l'objet de la mémoire globale du « <i>device</i> »
cudaMemcpy ()	copie des données de l'hôte vers le « <i>device</i> ». Nécessite quatre arguments : le pointeur destination, le pointeur source, le nombre d'octets et le mode de transfert.



L'interface mémoire entre l'hôte et le «device» :



*La mémoire globale en bas du schéma est le moyen de communiquer des données entre l'hôte et le «device».*

*Le contenu de la mémoire globale est visible depuis toutes les threads et est accessible en lecture/écriture, celle indiquée «constant memory», n'est accessible qu'en lecture seulement.*

*La mémoire partagée par bloc est visible depuis toutes les threads de ce bloc.*

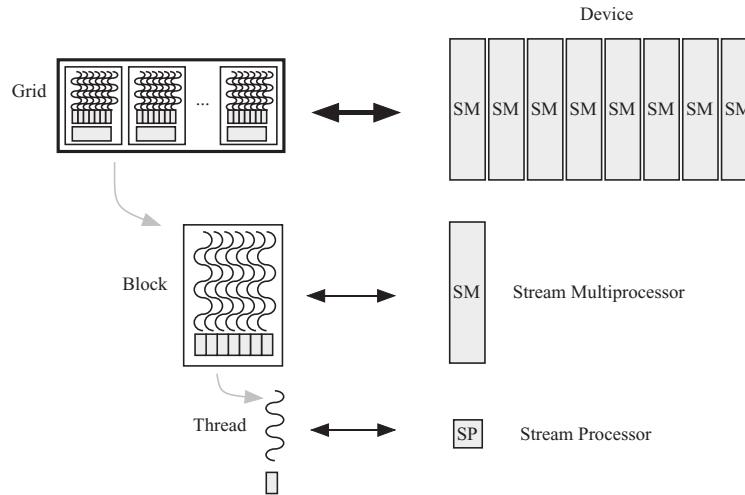
*La mémoire locale, comme les registres, n'est visible que de la thread.*



## Exécution d'une application parallèle sur le «device»

22

L'hôte déclenche une fonction «kernel» :



- ◊ Le «*kernel*» est exécuté sur une grille de blocs de threads.
- ◊ Différents «*kernels*» peuvent être exécutés par le «*device*» à différents moments de la vie du programme.
- ◊ Chaque bloc de threads est exécuté sur un multiprocesseur à flux, «*streaming multiprocessor*», «*SM*».
- ◊ Le *SM* exécute plusieurs blocs de threads à la fois.
- ◊ Des copies du «*kernel*» sont exécutées sur le «*streaming processor*», «*SP*», ou «*thread processors*», ou «*Cuda core*», qui exécute une thread qui évalue la fonction.
- ◊ Chaque thread est allouée à un *SP*.

Actuellement, dans les salles de TP :

- ▷ au plus 1024 threads par dimension du bloc qui communiquent par mémoire partagée ;
- ▷ chaque dimension d'une grille doit être inférieure à 65536 ;
- ▷ la mémoire partagée dans un block  $\simeq 16Ko$  ;
- ▷ la mémoire constante  $\simeq 64Ko$  ;
- ▷ nombre de registres disponibles par block 8192 à 16384.



# Comment est-ce que cela se passe dans le GPU ?

23

## Utilisation du profiler nvprof

Exemple sur l'exercice du TD n°1 :

```
$ nvprof ./TD1
==21398== NVPROF is profiling process 21398, command: ./TD1
Result : 25723564731392.000000
==21398== Profiling application: ./TD1
==21398== Profiling result:
      Type    Time(%)      Time      Calls       Avg        Min        Max     Name
GPU activities:   84.51%  45.057us           2  22.528us  22.272us  22.785us  [CUDA memcpy HtoD]
                  14.05%  7.4880us           1  7.4880us  7.4880us  7.4880us  dot(double*, double*)
double*, double*)①
                  1.44%    768ns           1    768ns    768ns    768ns  [CUDA memcpy
DtoH]
API calls:    99.23% 125.79ms           3  41.930ms  6.2840us  125.66ms  cudaMalloc
               0.34% 429.54us          94  4.5690us   524ns  173.12us  cuDeviceGetAttribute
               0.20% 249.19us           3  83.064us  10.325us  121.90us  cudaFree
               0.09% 115.94us           3  38.646us  14.710us  56.079us  cudaMemcpy
               0.08% 103.67us           1  103.67us  103.67us  103.67us  cuDeviceTotalMem
               0.03% 44.132us           1  44.132us  44.132us  44.132us  cuDeviceGetName
               0.02% 24.364us           1  24.364us  24.364us  24.364us  cudaLaunch
               0.00% 2.5540us           3    851ns   532ns  1.3180us  cuDeviceGetCount
               0.00% 1.4740us           2    737ns   590ns  884ns  cuDeviceGet
               0.00%  943ns             1    943ns   943ns  943ns  cudaConfigureCall
               0.00%  930ns             3    310ns   142ns  529ns  cudaSetupArgument
②
```

Le **profiler** fournit les informations suivantes :

- le **nombre d'appels** des différentes fonctions (sous la rubrique «*Calls*») ;
- le temps d'exécution des **différentes fonctions CUDA** ② ;
- le temps d'exécution du **kernel** (①, le kernel qui ici s'appelle `dot`) ;
- le **rapport** entre le temps d'exécution du **kernel** et des **transferts de mémoire** ③.



# Comment est-ce que cela se passe dans le GPU ?

24

## Utilisation du profiler nvprof

Ici, on va demander à récupérer des informations concernant les activités du GPU avec l'option --print-gpu-trace:

```
$ nvprof --print-gpu-trace ./TD1
==21538== NVPROF is profiling process 21538, command: ./TD1
Result : 25723564731392.000000
==21538== Profiling application: ./TD1
==21538== Profiling result:
      Start Duration          Grid Size     Block Size   Regs*    SSMem*    DSMem*     Size Throughput
SrcMemType DstMemType           Device       Context     Stream  Name
228.80ms  22.913us           GeForce GTX 106  -        1      -      - [CUDA memcpy HtoD]  -  264.00KB 10.988GB/s
Pageable   Device
228.84ms  22.208us           GeForce GTX 106  -        1      -      - [CUDA memcpy HtoD]  -  264.00KB 11.337GB/s
Pageable   Device
228.87ms  7.4560us          (132 1 1)❶      (256 1 tkzapf2 13❷ 2.0000KB 0B
-          -           GeForce GTX 106      7 dot(double*, double*, double*) [111]
-          -
228.88ms  768ns             GeForce GTX 106  -        1      -      - [CUDA memcpyDtoH]  -  1.0313KB 1.2806GB/s
Device    Pageable
Rgs: Number of registers used per CUDA thread. This number includes registers used internally by the CUDA driver and/or tools and can be more than what the compiler shows.
SSMem: Static shared memory allocated per CUDA block.
DSMem: Dynamic shared memory allocated per CUDA block.
SrcMemType: The type of source memory accessed by memory operation/copy
DstMemType: The type of destination memory accessed by memory operation/copy
```

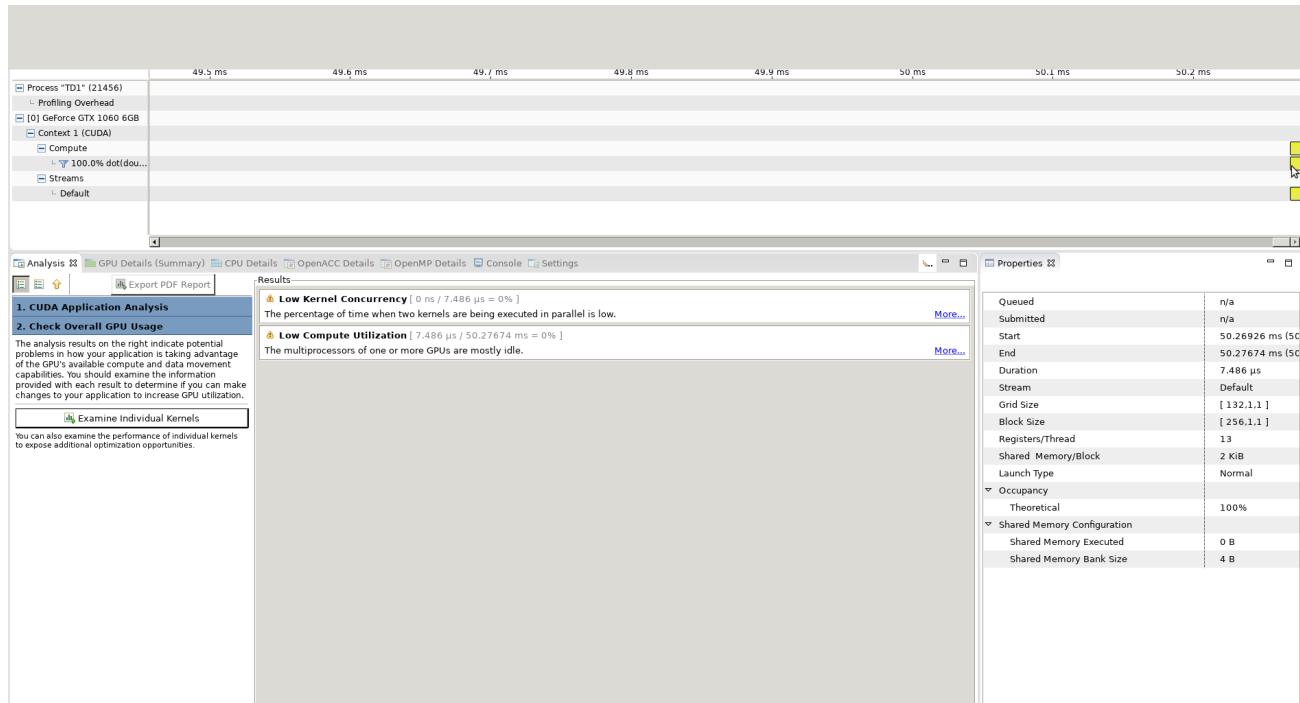
On obtient des informations sur le code PTX, «Parallel Thread eXecution» produit:

- ❶⇒la géométrie de la grille ;
- ❷⇒celle du bloc ;
- ❸⇒le nombre de registres utilisés par thread, c-à-d le nombre de variables locales utilisées par le kernel (si on dépasse, on est obligé d'utiliser de la mémoire locale à la thread moins performante).



# Comment est-ce que cela se passe dans le GPU ?

25

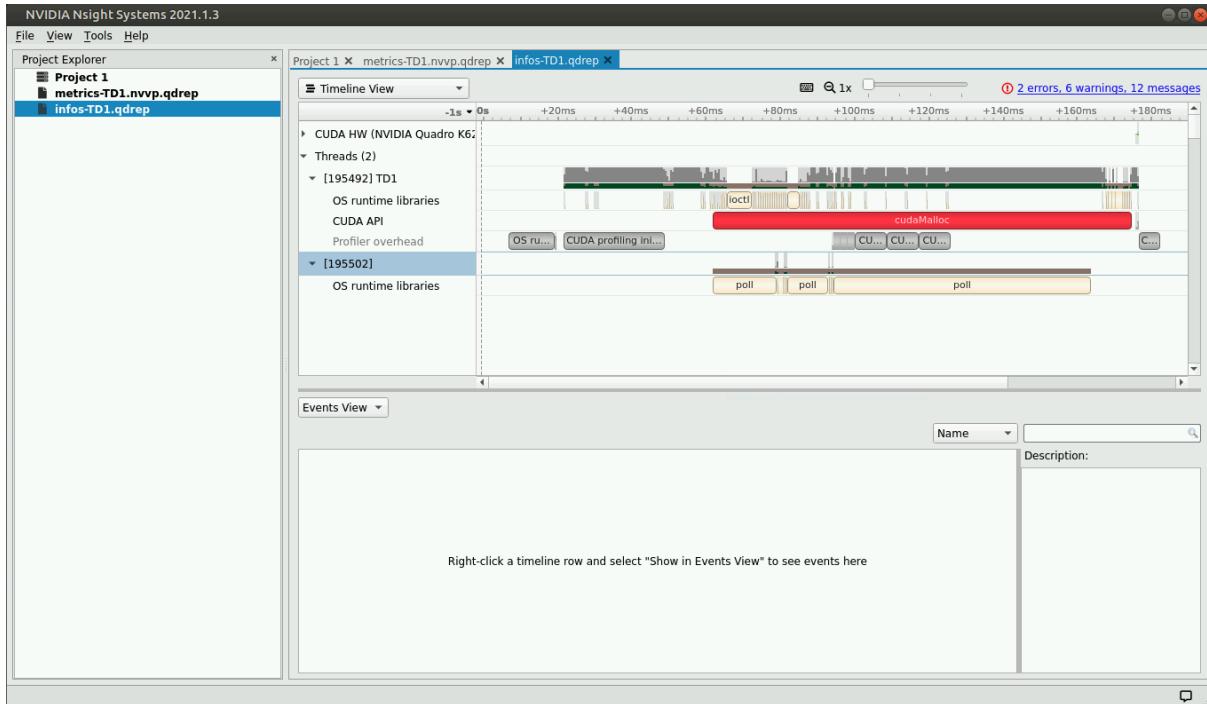


Une copie d'écran de l'outil «nvvp».



# Comment est-ce que cela se passe dans le GPU ?

26



Une copie d'écran de l'outil «nsight».


La commande utilisée :

```
└── xterm └──
$ nsy profile -w true -t cuda,nvtx,osrt,cudnn,cublas -s cpu --cudabacktrace=true -x true -o
infos-TD1 ./TD1
```



## La notion de «stream»

- sur une carte pro : plusieurs streams possibles ;
- sur une carte grand public : un seul stream.



Ici, la carte GPGPU est capable de supporter plusieurs streams, mais offre un accès séquentielle pour les transferts des données de l'hôte vers la carte, «Copy To device».

### Attention

La possibilité de faire des transferts **asynchrones**, c-à-d de «recouvrir» des communications par du calcul est obtenu à l'aide de la fonction `cudaMemcpyAsync()` :

- ▷ la copie de mémoire **vers le GPGPU** depuis le CPU peut être réalisé en **même temps** que du travail sur le CPU (le GPU récupère ses données simultanément) ;
- ▷ la copie **vers et depuis** le GPU peut être faire pendant que le GPU réalise du travail.

Cette capacité est disponible suivant la capacité CUDA de la carte nvidia utilisée.



## La notion de «warp»

28

Soit le programme suivant et sa parallélisation :



```
void some_func(void)
{
    int i;
    for (i=0;i<128;i++)
        { a[i] = b[i] * c[i]; }
}
```

On parallélise la boucle en créant une thread par occurrence de la boucle :

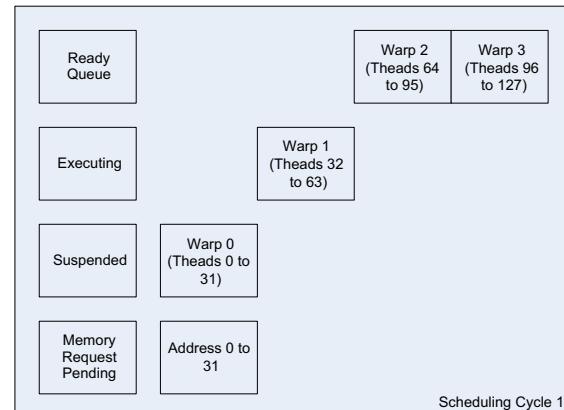
```
__global__ void some_kernel_func(int *a, int *b, int *c)
{   unsigned int thread_idx = threadIdx.x;
    a[thread_idx] = b[thread_idx] * c[thread_idx]; }
```

Un «warp»

- ▷ correspond à 32 threads ;
- ▷ exécute du code SPMD, ou SPMT, «*Simple Program Multiple Thread*»,
- ▷ est ordonné, *scheduled*, dans le SP, suivant son état :



Le «Warp 0» progresse de «Ready Queue» à «Executing».



Le «Warp 0» réalise des demandes d'accès mémoire et se suspend : c'est le «Warp 1» qui s'exécute.




# La notion de «warp»

29

Le «scheduler» fait progresser le warp de l'état prêt, «Ready Queue», à l'état exécuté, «Executing».

Dans le cas où le warp réclame du contenu dans la mémoire : il passe en «Suspended» et des accès mémoires attendent d'être résolus : «Memory Request Pending».



Toutes les threads sont bloquées en attente du retour des données depuis la mémoire...

Les données 0 à 63 sont obtenues : les threads 0 à 31 sont exécutées et les threads 32 à 63 sont prêtes.



## La notion de divergence

```
__global__ some_func(void)
{
    if (some_condition)
    {
        action_a(); // +
    }
    else {
        action_b(); // -
    }
}
```

*Imaginons que les threads paires réalisent le travail positif et les threads impaires le travail négatif par rapport à la condition :*

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
+	-	+	-	+	-	+	-	+	-	+	-	+	-	+	-	+

Le Warp exécute du code SPMT : les threads «+» s'exécutent pendant que les autres sont bloquées.

Une solution : l'association par demi warp, soient 16 threads :

```
if ((thread_idx % 32) < 16)
{
    action_a();
}
else {
    action_b();
}
```

On bénéficie

- \* d'une exécution parallèle de la partie «+» et «-» sur chacun des demi-warps en SPMT ;
- \* éventuellement d'accès mémoire sur  $4 * 16 = 64$  octets pour les données sur 32bits utilisées par le demi-warp ;




### 3 La notion de divergence

31

Soit le code suivant:

```
// Coherent code
if (a >b) {
    a++;
    someFunction(a);
} else {
    b++;
    someFunction(b);
    someFunction(a);
}
// Coherent Code
```

#### Les effets sur le Warp



⇒ Le travail des threads est le même : elles font toutes le travail des deux branches mais on annule le résultat du travail inutile.




**Exemple de code**

```
#define WARP_SIZE 32
#define BLOCK_SIZE 2*WARP_SIZE
#define GRID_SIZE 16

...
dim3 dimBlock(BLOCK_SIZE);
dim3 dimGrid(GRID_SIZE);
...
divergence<<<dimGrid, dimBlock>>>(ref_a, ref_b);
```

Dans le kernel, la numérotation de la thread est similaire à l'index du tableau de données :

```
int a = blockIdx.x*blockDim.x + threadIdx.x;
```

**Répartition du code entre les blocs et les threads**


- ▷ chaque bloc dispose de 64 threads, soient 2 Warps ;
- ▷ il y a 16 blocs dans la grille.



## Exemples de Kernels : «divergence» et «noDivergence»

```
__global__ void divergence(float *A, float *B) {
    int a = blockIdx.x*blockDim.x + threadIdx.x;
    if((threadIdx.x % WARP_SIZE) == 0)
    {
        for(int i=0;i<ITERATIONS;i++) {
            B[a]=A[a]+1;
        }
    } else
        for(int i=0;i<ITERATIONS;i++) {
            B[a]=A[a]-1;
        }
}
```


*th<sub>0</sub>, th<sub>32</sub>*  
*autres threads*



Une seule thread effectue un travail différent (la première thread du warp, en rouge sur le schéma).

```
__global__ void noDivergence(float *A, float *B) {
    int a = blockIdx.x*blockDim.x + threadIdx.x;
    if(threadIdx.x >= WARP_SIZE)
    {
        for(int i=0;i<ITERATIONS;i++) {
            B[a]=A[a]+1;
        }
    } else
        for(int i=0;i<ITERATIONS;i++) {
            B[a]=A[a]-1;
        }
}
```

*th<sub>32</sub>, th<sub>33</sub> à th<sub>63</sub>*  
*th<sub>0</sub>, th<sub>1</sub> à th<sub>31</sub>*



Un warp complet réalise chaque branche de la condition (en rouge sur le schéma).



## Au niveau de l'exécution

Sans divergence : un warp complet exécute une des branches de la condition.

```
└── xterm └──
pef@fpga:~/CUDA/MESURES_PERFS$ ./divergence
kernel invocation
Sans divergence
kernel execution time (msecs): 154.822556 ms
32 -> 1.000000.0 33 -> 1.000000.0 34 -> 1.000000.0 35 -> 1.000000.0 36 ->
1.000000.0 37 -> 1.000000.0 38 -> 1.000000.0 39 -> 1.000000.0 40 -> 1.000000.0
41 -> 1.000000.0 42 -> 1.000000.0 43 -> 1.000000.0 44 -> 1.000000.0 45 ->
1.000000.0 46 -> 1.000000.0 47 -> 1.000000.0 48 -> 1.000000.0 49 -> 1.000000.0
50 -> 1.000000.0 51 -> 1.000000.0 52 -> 1.000000.0 53 -> 1.000000.0 54 ->
1.000000.0 55 -> 1.000000.0 56 -> 1.000000.0 57 -> 1.000000.0 58 -> 1.000000.0
59 -> 1.000000.0 60 -> 1.000000.0 61 -> 1.000000.0 62 -> 1.000000.0 63 ->
1.000000.0 96 -> 1.000000.0 97 -> 1.000000.0 98 -> 1.000000.0 99 -> 1.000000.0
100 -> 1.000000.0 101 -> 1.000000.0 102 -> 1.000000.0 103 -> 1.000000.0 104 ->
1.000000.0 105 -> 1.000000.0 106 ->
...

```

Sans divergence : un thread par warp introduit une divergence :

```
└── xterm └──
pef@fpga:~/CUDA/MESURES_PERFS$ ./divergence yes
kernel invocation
Avec divergence
kernel execution time (msecs): 290.697205 ms
0 -> 1.000000.0 32 -> 1.000000.0 64 -> 1.000000.0 96 -> 1.000000.0 128 ->
1.000000.0 160 -> 1.000000.0 192 -> 1.000000.0 224 -> 1.000000.0 256 ->
1.000000.0 288 -> 1.000000.0 320 -> 1.000000.0 352 -> 1.000000.0 384 ->
1.000000.0 416 -> 1.000000.0 448 -> 1.000000.0 480 -> 1.000000.0 512 ->
1.000000.0 544 -> 1.000000.0 576 -> 1.000000.0 608 -> 1.000000.0 640 ->
1.000000.0 672 -> 1.000000.0 704 -> 1.000000.0 736 -> 1.000000.0 768 ->
1.000000.0 800 -> 1.000000.0 832 -> 1.000000.0 864 -> 1.000000.0 896 ->
1.000000.0 928 -> 1.000000.0 960 -> 1.000000.0 992 -> 1.000000.0

```

⇒ Les performances vont du simple au double !



Lorsqu'un programme parallèle est exécuté sur le «device», la synchronisation et les communications parmi les threads doivent être réalisées à différents niveaux :

1. «Kernels» et «grids» ;
2. Blocs ;
3. Threads.

## Grille & Kernels

Différents «kernels» peuvent être exécutés sur le «device».

```
void main() {  
...  
kernel_1<<<nblocks_1, blocksize_1>>>(fonction_argument_liste_1)  
kernel_2<<<nblocks_2, blocksize_2>>>(fonction_argument_liste_2);  
...}
```

- \* kernel\_1 va être exécuté en premier sur le «device» :
  - ◊ il va définir une grille qui contiendra dimGrid blocs, chacun de ces blocs contiendra dimBlock threads.
  - ◊ toutes les threads vont exécuter le même code spécifié par le «kernel».
- \* lorsque kernel\_1 aura terminé, alors kernel\_2 sera transmis vers le «device» pour son exécution.

### Attention

Le communication entre les différentes grilles est **indirecte** : elle consiste à laisse en place les données dans l'hôte ou la mémoire globale du «device» pour être utilisées par le prochain «kernel».



## Les blocs

- \* Tous les blocs d'une grille s'exécutent indépendamment les uns des autres : il n'y a **pas de mécanisme de synchronisation** entre les blocs.
- \* lorsqu'une grille est lancée, les blocs sont assignés à un SM, dans un **ordre arbitraire** qui n'est pas **prédictible**.

Les communications entre les threads à l'intérieur d'un bloc sont réalisées au travers de la **mémoire partagée du bloc** :

- ◊ une variable est déclarée comme étant partagée par les threads du même bloc en préfixant sa déclaration à l'aide du mot-clé «\_\_shared\_\_».  
*Cette variable est alors stockée dans la mémoire partagée du bloc.*
- ◊ lors de l'exécution d'un «kernel», une version privée de cette variable est créée dans la mémoire locale de la thread.

## Des temps d'accès mémoire différents

- ◊ La **mémoire partagée** associée au bloc est sur la même puce que les **coeurs**, «cores», exécutant les threads ;  
La communication est relativement rapide, car la SRAM, «*Static RAM*», est plus rapide que la mémoire située en dehors de la puce, «off-chip» de type DRAM ;
- ◊ chaque thread dispose d'un **accès direct à ses registres** inclus dans la puce et d'un accès direct à sa mémoire locale qui est en «off-chip». *Les registres sont beaucoup plus rapides que la mémoire locale* ;
- ◊ chaque thread peut également avoir **accès à la mémoire globale** du «device» ;
- ◊ l'accès d'une thread à la mémoire locale et globale souffre des problèmes inhérents aux communications entre puces, «*interchip*» : *retard, consommation de puissance, débit*.



## Les threads et le SIMD : la notion de «warp»

Un grand nombre de threads sont exécutées sur le «device».

Un bloc qui est assigné à un SM est divisé en groupe de 32 threads *warps*. Chaque warp représente le «SIMD» du GPU.

Chaque SM peut gérer plusieurs «warps» simultanément, et lorsque certains «warps» sont bloqués à cause d'accès à la mémoire, le SM peut ordonner l'exécution d'un autre «warp» (suivant un scheduler).

- ◊ Les threads d'un **même bloc** peuvent se synchroniser à l'aide de la fonction `__syncthreads()`, réalisant une barrière de synchronisation entre les différents warps exécutés.
- ◊ une thread peut utiliser une opération **atomique** pour obtenir l'accès exclusif à une variable pour un réaliser une opération donnée: `atomicAdd(result, input[threadIdx.x])` coûteux en synchronisation.
- ◊ Chaque thread utilise ses registres et sa mémoire locale, qui utilise tous les deux de la SRAM, ce qui induit une petite quantité de mémoire disponible, mais des communications rapides et peut coûteuse en énergie.
- ◊ Chaque thread peut également utiliser la mémoire globale qui est plus lente car elle utilise de la DRAM.

## La répartition des variables entre les différentes zones mémoire

Pour définir la localisation, on utilise des préfixe pour la déclaration ou des règles automatiques.

Déclaration	Lieu de stockage de la variable	Pénalité	Portée	Lifetime
<code>int var;</code>	un registre de la thread		thread	thread
<code>int tableau[10];</code>	la mémoire locale de la thread		thread	thread
<code>__shared__ int var;</code>	la mémoire partagée du bloc		bloc	bloc
<code>__device__ int var;</code>	la mémoire globale du «device»	<i>plus lent</i>	grille	application
<code>__constant__ int const;</code>	la mémoire constante du bloc.		grille	application

Les variables `__constant__` et `__device__` sont à déclarer en dehors de toute fonction.



### Des accès décalés ou répartis

*permet de choisir float ou double*

```
template <typename T> __global__ void offset(T* a, int s)
{
    int i = blockDim.x * blockIdx.x + threadIdx.x + s;
    a[i] = a[i] + 1;
}
template <typename T> __global__ void stride(T* a, int s)
{
    int i = (blockDim.x * blockIdx.x + threadIdx.x) * s;
    a[i] = a[i] + 1;
}
```

```
int blockSize = 256; // taille du bloc
...
int n = nMB*1024*1024/sizeof(T); // si nMB = 4, n=1048576
...
checkCuda( cudaMalloc(&d_a, n * 33 * sizeof(T)) ); // 33*1024*1024 var. type T
...
offset<<<n/blockSize, blockSize>>>(d_a, i); // la grille est de 4096 blocs
...
if (bFp64) runTest<double>(deviceId, nMB); // on utilise des doubles
else        runTest<float>(deviceId, nMB); // ou des floats
```

bloc<sub>0</sub>

bloc<sub>1</sub>


bloc<sub>4095</sub>



256



...



grid → 4096 blocs, soient 1024\*1024 threads



## Décalage des accès ou «offset»

On décale 32 fois :


```
for (int i = 0; i <= 32; i++) {
    offset<<<n/blockSize, blockSize>>>(d_a, i);
    ...
    printf("%d, %f\n", i, 2*nMB/ms); // on mesure le débit
}
```

Le travail du Kernel :


```
__global__ void offset(T* a, int s)
{
    int i = blockDim.x * blockIdx.x + threadIdx.x + s;
    a[i] = a[i] + 1;
}
```



addition

## Offset de zéro



## Offset de un



Aggrégation, «*coalescence*», des accès mémoire : décalage

## Saut des accès ou «stride»

On accède à 2 fois, puis 3 fois, etc:


```
for (int i = 0; i <= 32; i++) {
    stride<<<n/blockSize, blockSize>>>(d_a, i);
    ...
    printf("%d, %f\n", i, 2*nMB/ms); // on mesure le débit
}
```

Le travail du Kernel :

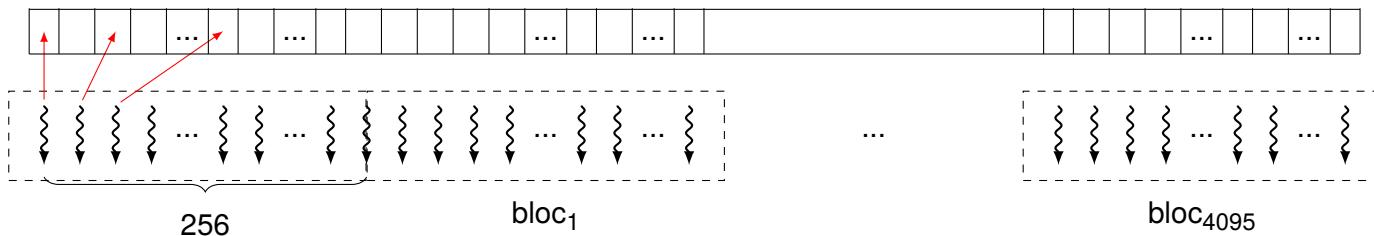
```
__global__ void offset(T* a, int s)
{
    int i = blockDim.x * blockIdx.x
            + threadIdx.x * s;
    a[i] = a[i] + 1;
}
```

*multiplication*


## Saut de zéro



## Saut de un



## Aggrégation, «coalescence», des accès mémoire : saut




## Que se passe-t-il au niveau du contrôleur de mémoire

Des accès **non alignés** et non contigus à la mémoire nécessitent plusieurs «*transactions*» mémoire.

Une **transaction** correspond à un accès mémoire suivant la **taille du bus de données**.

*Exemple : sur une carte GTX 1060, le bus de données est de 192bits, soient une transaction de 6 données sur 32bits simultanément.*



Sur le schéma la taille du bus est de  $4 * 32\text{bits}$  soient  $128\text{bits}$ .



## Exemple de code utilisant la «*shared memory*»

```
// Calcul de différence de données adjacentes
// calculer result[i] = input[i] - input[i-1]
__device__ int result[N];

__global__ void adj_diff_naive(int *result, int *input)
{
    // calculer l'identifiant de la thread en fonction
    // de sa position dans la grille
    unsigned int i = blockDim.x * blockIdx.x + threadIdx.x;

    if(i > 0)
    {
        // Utiliser des variables locales à la thread
        int x_i = input[i];
        int x_i_minus_one = input[i-1];
        // Deux accès sont nécessaires pour i et i-1
        result[i] = x_i - x_i_minus_one;
    }
}

// version optimisée
__device__ int result[N];
__global__ void adj_diff(int *result, int *input)
{
    // raccourci pour threadIdx.x
    int tx = threadIdx.x;
    // allouer un __shared__ tableau,
    // un élément par thread
    __shared__ int s_data[BLOCK_SIZE];
    // chaque thread lit un élément dans s_data
    unsigned int i = blockDim.x * blockIdx.x
                    + tx;
    s_data[tx] = input[i];


    // éviter une race condition: s'assurer
    // des chargements avant de continuer
    __syncthreads();
    if(tx > 0)
        result[i] = s_data[tx] - s_data[tx-1];
    else if(i > 0)
    { // traiter les accès aux bords du bloc
        result[i] = s_data[tx] - input[i-1];
    }
}
```

Cette optimisation se traduit par une nette amélioration des performances : 36,8GB/s vs 57.5GB/s.




La mémoire partagée est **répartie** en module de mémoire ou «bank» :

- chaque module de mémoire ou «bank» est de **taille identique** ;
- chaque module est **connecté** à chaque cœur par un réseau de type «crossbar» ;
- chacune de ces «banks» peut être **accédée simultanément** s'il n'y a pas de conflit d'accès :



*Accès simultanés*




*Conflit : les accès sont sérialisés.*


- la mémoire partagée est constituée de **32 banks** pour toutes les architectures CUDA : de 4.5 à 8.6 ;
- 32 banks pour un warp de 32 threads  $\Rightarrow$  des **conflits** peuvent arriver !
- chaque module à un **débit** de 32bits par cycle d'horloge ;
- l'accès en écriture ou en lecture de  $n$  adresses quelconques dans des **banks distinctes** peut être fait **simultanément**  $\Rightarrow$  le débit peut atteindre  $n$  fois le débit d'une seule bank !



- Si **toutes les threads** accèdent en lecture à la **même donnée** sur 32bits comprise dans la **même bank**, alors cette valeur est accédée en un seul cycle et «*broadcastée*» à chaque thread :



Comment les données sont organisées entre les différentes banks ?



les données sont réparties de manières régulières entre les différentes banks : les données successives sont réparties dans des banques successives ;





## Accès sans conflit : exemple pour 16 threads

```
__shared__ float partage[32];  
  
float data = partage[threadIdx.x];
```

Les données sont réparties entre les différentes banks :

- ▷ *partage[0]* est dans la bank 0;
- ▷ ...
- ▷ *partage[31]* est dans la bank 31;



Cela peut également arriver avec :

```
__shared__ short partage[32];
```

Un *short* est sur 16bits soient un conflit d'accès double sur 32bits

## Conflit :

```
__shared__ double partage[32];  
  
double data = partage[threadIdx.x];
```

Ici, les données sont des *double*, soient 64 bits ou 2\*32bits :

- ▷ *partage[0]* est dans la bank 0 pour ses premiers 32bits et dans la bank 1 pour ses derniers 32bits
- ▷ *partage[16]* est dans la bank 0 pour ses premiers 32bits et dans la bank 1 pour ses derniers 32bits

⇒ Conflits d'accès double !



## **Encore des conflits ?**

Les données sont groupées par 32bits :

```
__shared__ char partage[32];
```

```
char valeur = partage[threadIdx.c];
```


**Comment résoudre les conflits**  
En décomposant un double en

$\Rightarrow$  pas bien !

En utilisant du «*padding*» :

## Solution :


```
__shared__ char partage[32];  
  
char data = shared[4 * threadIdx.x];
```



On ajoute une colonne qui ne sert qu'à réaliser un décalage et éviter le conflit.



- \* la **mémoire globale** réside dans la mémoire globale du «device» en DRAM (plus lente) ;
- \* il faut **partitionner les données** pour tirer parti de la **mémoire partagée** plus rapide :
  - ◊ utiliser la technique vu sur le transparent précédent ;
  - ◊ utiliser une méthode «divide and conquer»



Comment aller plus loin ?  
Exécuter plusieurs instructions à la fois  
dans la **même thread**




```

1 x := y + 1
2 z := y + z + 10 * t
3 w := x + z
  
```

L'obtention du résultat à partir de  $x$ ,  $y$  et  $z$  nécessite **plusieurs étapes** dont certaines peuvent **s'exécuter en parallèle**.

## Graphe de précédence

- les nœuds sont les **opérations à réaliser** pour résoudre le problème ;
- les **arcs orientés** sont les **contraintes de précédence** entre les opérations.



⇒ On obtient un **ordre partiel** et les **opérations non ordonnées** par cet ordre partiel sont :

- ▷ **indépendantes**
- ▷ capables de s'exécuter **en parallèle**.

*Sur l'exemple :*

- ▷ **1** et **2** peuvent s'exécuter **en parallèle** ;
- ▷ *par contre* **3** doit attendre la fin de **1** et **2** avant de débuter.

Le **graphe de précédence** donne une **analyse statique du parallélisme fonctionnel** exploitable :

- la **longueur de son plus long chemin** donne le nombre d'opérations **nécessairement séquentielles** ;
- la **largeur du graphe** donne le **nombre maximum d'opérations exécutables en parallèle** (le degré moyen des nœuds du graphe est également important).



## Deux types de source de parallélisme

- le **parallélisme fonctionnel** ou **parallélisme de contrôle** ;
- le **parallélisme de données**.

### Parallélisme fonctionnel

Il correspond à :

- ▷ découper un problème en **tâches** (opérations élémentaires) ;
- ▷ indiquer **l'ordonnancement** de ces tâches (graphe de précédence).

#### Exemple : produit itératif de $n$ éléments

```
P := a(0) ;
Pour i in 1 .. n - 1 faire
    P := P * a(i) ;
```

$P$  est le produit du premier élément avec le produit des  $n-1$  éléments.

#### Analyse :

- le temps d'exécution est linéaire en  $n$ , soit  $O(n)$  ;
- son **graphe de précédence** est une **chaîne** : il ne peut être parallélisable.

Pourtant il est **facile** de concevoir un **algorithme parallèle** à l'aide de  $n$  processus en  $O(\log_2(n))$ .


Mais ici, on exploite une **propriété de la multiplication** : son **associativité**.



**Exemple :** produit itératif de  $n$  éléments

```
P := a(0) ;
Pour i in 1 .. n - 1 faire
    P := P * a(i) ;
```

$P$  est le produit du premier élément avec le produit des  $n-1$  éléments.



Ici, l'**algorithme parallèle** à l'aide de  $n$  processus est en  $O(\log_2(n))$



## Parallélisme de données


Dans ce cas là, la même opération (SIMD) ou le même programme (SPMD) est effectué sur des données différentes.

Ce **parallélisme** est souvent exploitable pour des programmes travaillant sur des **vecteurs**.

Exemple : soient les vecteurs  $a[ ]$ ,  $b[ ]$  et  $r[ ]$ . Calculer  $r[i] = a[i] \text{ } \$ \text{ } b[i]$  pour  $i = 0, \dots, n - 1$  avec  $\$$  étant un opérateur quelconque

Il existe deux façons de l'exploiter :

- le mode **parallèle** sur les données : Les opérations  $r[i] = a[i] \text{ } \$ \text{ } b[i]$  sont indépendantes, le graphe de précédence est constitué d'éléments simples, non interconnectés :



Cette forme de parallélisme est dite «*parfaite*».

Il nécessite parfois une **fusion des résultats** obtenus pour obtenir le **résultat final** (exemple : la somme de tous les  $r[i]$ ).

*Certain langages de programmation parallèle comme HPF, «High Performance Fortran», ou OpenMP disposent d'instructions et d'outils automatiques pour l'exploiter (**opération de réduction**).*




## Le mode pipeline

On suppose qu'une opération  $\$$  :

- est **complexe à effectuer**
- peut être découpée en  $k$  sous-calculs successifs  $E_1, \dots, E_k$  **plus simples.**

$$a\$b = E_k(E_{k-1}(((\dots(E_1(a, b))\dots)))$$



Ce qui donne :

- ▷ à l'étape 1 : on calcule  $r[0]_1 = E_1(a[0], b[0])$  ;
- ▷ à l'étape 2 : on calcule  $r[0]_2 = E_2(r[0]_1)$  ;
- ▷ etc.

Au bout de  $k$  étapes, le résultat  $r[0] = r[0]_k = a[0]\$b[0]$  est obtenu en sortie de  $E_k$ .

On alimente la série d'opérateurs  $E_i$  de **manière continue** pour obtenir l'effet pipeline.

Chaque  $E_i$  est appelé «étage» du pipeline  $\Rightarrow$  il est choisi pour durer «un cycle d'horloge».


Le **temps de calcul global** est alors  $k + n - 1$  au lieu de  $k * n$ .

L'accélération est de  $\frac{k*n}{k+n-1} \asymp k$  pour des grandes valeurs de  $n$ .




## Exploiter le potentiel parallèle : Effet pipeline

56






Si chaque  $E_i$  prend **un cycle d'horloge** alors une valeur sort du pipeline à **chaque cycle d'horloge**.  
 ⇒ On est passé d'une opération § sur **3 cycles d'horloge** à une opération § sur un **cycle d'horloge** !






Un étage fait 2 cycles ?  
 ▷ dupliquer l'étage ;  
 ▷ mettre un «switch»,  $\otimes$ , qui alterne à chaque cycle le branchemet vers l'un des deux étages dupliqués en entrée et en sortie.  
 => On obtiendra **un résultat à chaque cycle d'horloge** en sortie du pipeline !






1. IF «*Instruction Fetch*» : charge l'instruction à exécuter dans le pipeline ;
  2. ID «*Instruction Decode*» : décode l'instruction et adresse les registres ;
  3. EX «*Execute*» : exécute l'instruction (par la ou les unités arithmétiques et logiques).
  4. MEM «*Memory*» : ◊ STORE : registre vers mémoire (accès en écriture) ;  
◊ LOAD : mémoire vers registre (accès en lecture) ;
  5. WB «*Write Back*» : stocke le résultat dans un registre.
- La source de ce résultat peut être :
- ◊ la mémoire (à la suite d'une instruction LOAD),
  - ◊ l'unité de calcul (à la suite d'un calcul à l'étape EX)
  - ◊ un registre (cas d'une instruction MOV).



## Pipeline




Le **pipeline** permet **d'accélérer** le travail du processeur :

- ▷ **sans pipeline** : **15 cycles d'horloges** pour exécuter **3 instructions** ;
- ▷ **avec pipeline** : **9 cycles** pour exécuter **5 instructions** puis on a **une instruction par cycle** après !



Une architecture «*superscalaire*» dispose de plusieurs pipelines en parallèle.

Exemple avec un processeur superscalaire de degré 2 :




2 instructions sont chargées simultanément depuis la mémoire.

Chaque pipeline peut être **spécialisé** dans le traitement **d'un certain type d'instruction**: seules des instructions de types **compatibles** peuvent être exécutées simultanément dans le pipeline associé.

**Problèmes avec l'utilisation de pipeline ?**


① ADD 1 to R5
② COPY R5 to R6

- ▷ ① commence à  $t_1$  et termine à  $t_5$
- ▷ ② commence à  $t_2$  et finit à  $t_6$



⇒ La valeur utilisée par l'instruction ② n'est **pas la bonne** !

⇒ C'est au **compilateur** de tenir compte de cela !



Les **CPUs** sont optimisés pour la «*latence*» :

- pipeline**, «*out-of-order*», **superscalaire** ;
- mémoire cache**, contrôleur mémoire intégré ;
- exécution **spéculative**, «*branch prediction*» prédition de condition ;
- les **cœurs** occupent une petite portion du circuit ;

Le cas de **blocage** d'une *thread* sont :

- ▷ CPU/GPU : l'**échec** de l'accès à une mémoire au travers du **cache** ⇒ attente de données depuis la mémoire ;
- ▷ CPU : **échec** de la **prédition** de condition : la «*branche*» de la condition choisie n'est pas la bonne ;
- ▷ CPU/GPU : une **dépendance** de donnée : une instruction est en attente du résultat d'une autre instruction.
- **SIMD**, «*Single Instruction Multiple Data*» :
  - ◊ on calcule les différents éléments d'un **vecteur** en parallèle ;
  - ◊ on découpe le problème en **petits vecteurs**, calculés les uns après les autres.
  - ◊ le hardware supporte de l'**arithmétique** sur de grandes valeurs ;
- **SMT**, «*Simultaneous MultiThreading*» :
  - ◊ les instructions de différentes threads sont exécutées en parallèle : lorsqu'une thread est bloquée, une autre thread peut s'exécuter ;
  - ◊ décomposer un problème en différentes tâches et les assigner à différentes threads ;
  - ◊ le hardware supporte le multi-threading : l' «*Hyper-Threading*» d'Intel ;
- **SIMT**, «*Simple Instruction Multiple Threads*» :
  - ◊ traitement de vecteur et multi-threading **léger** ;
  - ◊ le **warp** est l'unité d'exécution : à chaque cycle il exécute la même instruction ;
  - ◊ ordonnancement de threads et changement de contexte rapide entre différents Warps permet de minimiser les blocages dus à des accès mémoire non résolus.

Les **GPUs** sont optimisés pour le débit :

- des centaines de **cœurs** de calcul ;
- coût minimal d'ordonnancer l'exécution de milliers de threads ;
- les cœurs de calcul occupent la majeur partie du circuit.



Au lancement d'un «*kernel*», on choisit :

- nombre de bloc** de threads ;
- nombre de warps** par bloc de threads ;
- la **taille de la mémoire partagée** par bloc de threads.

*Il est recommandé de déclencher plus de bloc de threads que l'on ne peut en exécuter en même temps.*

Lorsque **tous les warps** d'un bloc ont terminé, le **prochain bloc** de threads est déclenché.

Le **nombre de blocs** de threads exécutés en même temps dépend :

- ▷ de la **taille mémoire partagée** allouée par bloc de threads ;
- ▷ du **nombre de registres** utilisés par chaque warp ;

L'**occupancy** est :

$$\frac{\text{nombre de warps exécutés en même temps}}{\text{nombre maximal de warps exécutables en même temps}} \text{ exprimé en pourcentage.}$$

*Le nombre maximal de warps exécutables en même temps dépend de la «Compute capability» de l'architecture de la carte GPU, par exemple une GTX 1060 a une «compute capability» de 6.1.*



## CUDA Major.Minor

Certaines générations amènent des nouveautés : *Tensors, Ray Tracing*.

	CUDA				Pro					
architecture	Tesla	Fermi	Kepler	Maxwell	Pascal	Volta	Turing	Ampere	Lovelace	Hopper
année	2006	2010	2012	2014	2016	2017	2018	2020	2022	2024
major	1	2	3	5	6	7	7.5	8	9	10
		sm_20	sm_30	sm_50	sm_60	sm_70	sm_75	sm_80	sm_90?	sm_100c?
			sm_35	sm_52	sm_61	sm_72		sm_86		
			sm_37	sm_53	sm_62					

spécial HPC  
TensorCores

RT Cores, «ray-tracing»


Accélération obtenue à chaque changement d'architecture



### Comment mesurer le temps d'exécution d'un programme ?

- ▷ en exécution **séquentielle** : le temps total d'exécution est la somme du temps d'exécution de chaque instruction ;
- ▷ en exécution **concurrente** : le temps d'exécution d'une instruction peut se superposer à celui d'une autre et leur somme ne correspond au temps total d'exécution.

### Schéma d'activité d'une exécution concurrente :



chaque rectangle :

- ▷ correspond à une instruction, un warp, une transaction mémoire etc.
- ▷ temps de démarrage ;
- ▷ temps de fin ;

L'activité globale se déroule entre 0 et le cycle 10.

- «Concurrence» : le nombre d'éléments exécutés en même temps. Il peut être mesuré à chaque instant ou donner une valeur moyenne sur la durée de l'intervalle.

*Ici, la concurrence varie de 1 à 3 pour une valeur moyenne de 2.*

### Les métriques :

- «Latence» : la **valeur moyenne** des différentes latences de chaque élément c-à-d la différence entre leur fin et leur début.  
*Ici, les latences individuelles sont 1, 2 ou 3, soit une latence moyenne de 2;*
- «Débit», «throughput» ou rythme d'exécution : le nombre d'éléments qui se retrouvent dans l'intervalle de temps choisi divisé par la durée de cet intervalle.  
*Ici, 10 éléments sur une période de 10 cycles, soit un élément par cycle ;*

### Little's law

$$\text{concurrence moyenne} = \text{latence moyenne} * \text{débit}$$

Cette loi permet d'évaluer la «concurrence» nécessaire pour atteindre un certain débit d'exécution d'instructions comme celles arithmétiques et celles pour l'accès mémoire.



En utilisant la **loi de Little** sur les instructions :

- **latence d'instruction** : latence de «*dépendance de registre*» : c'est la partie du temps d'exécution total
  - ◊ qui débute quand l'instruction est «*issued*», c-à-d émise par l'unité de contrôle ;
  - ◊ qui finit quand l'instruction suivante dépendant de la valeur d'un registre peut être émise.
- Une instruction **dépendante de la valeur d'un registre** est une instruction qui utilise en **entrée**, la **sortie** d'une instruction donnée. Cette «*sortie*» est faite dans un registre.
- **débit** d'exécution d'instruction : nombre d'instructions exécutées divisé par un interval de temps ;
- **concurrence** : nombre d'instructions exécutées en même temps.

$$\text{débit d'instructions} = \frac{\text{instructions en cours d'exécution}}{\text{latence d'instruction}}$$

**Exemple** : sur un GPU d'**architecture Maxwell**, la latence d'une **instruction arithmétique** de base est de **6 cycles**.

- ▷ L'exécution d'**une instruction arithmétique à la fois** correspond à un débit de  $1/6$  instructions par cycle ou IPC, «*Instruction Per Cycle*».
- ▷ L'exécution de **deux instructions arithmétiques à la fois** donne un débit de  $1/3$  IPC.
- ▷ L'exécution de **trois instructions à la fois** donne un débit de  $1/2$  IPC,
- ▷ *etc.*

Dans l'architecture Maxwell, on dispose de 128 coeurs CUDA par SM, et on ne peut pas exécuter d'instructions arithmétique plus rapidement que 4 IPC par SM, car 1 instruction réalise 32 opérations arithmétiques (un warp).

Cette valeur représente le **débit de crête**, ou «*peak throughput*».

*La valeur dépend du type d'instruction mais aussi des conflits d'accès aux «banks», à la coalescence/divergence etc.*

### Comment atteindre le débit de crête ou le «*peak throughput*» ?

En utilisant la **loi de Little**, on calcule : latence instruction \* débit de crête =  $6 * 4 = 24$ ,  
 ⇒ il faut **24 instructions arithmétiques** par SM pour l'atteindre.



En utilisant la **loi de Little** sur l'accès à la mémoire :

- ▷ latence d'accès mémoire : dépend du fait que la mémoire demandée ne soit pas dans le cache, qu'elle soit de 32bits, qu'elle soit agrégée, «coalescence» et que seulement un ou un peu plus de ces accès soient demandés.  
exemple : sur l'architecture Maxwell, la latence d'un accès mémoire est de 368 cycles.

Le débit de crête est de 224GB/s.

Ce débit correspond à 0,086 IPC par SM.

Pour le déterminer, on calcul :  $\frac{\text{débit}}{\text{clock rate} * \text{nombre de SM} * \text{nombre d'octets demandés par instruction}}$ , ce qui donne :  $\frac{224}{1,266 * 16 * 128} = 0,086$

En utilisant la loi de Little, on obtient : concurrence =  $368 * 0,086 = 32$ , ce qui veut dire qu'il faut 32 accès mémoire pour atteindre ce débit de crête.

### Occupancy vs Instruction concurrency

La **concurrence** peut être définie de deux manière différentes :

- le **nombre de warps** exécutés en même temps ;
- le **nombre d'instructions** exécutées en même temps ;

*Est-ce la même chose ? Non !*

Exploiter de l'ILP, «*Instruction Level Parallelism*» dans un code signifie que ce code permet d'exécuter **plus d'une instruction en même temps** et pour le **même warp**.

Mais seulement si ces deux instructions sont **indépendantes**, c-à-d que le registre de sortie de l'une n'est pas utilisé comme entrée de l'autre  $\Rightarrow$  dépendance de registre.

### Comment faire ?

En utilisant **moins de warps** !

*Par exemple : si en moyenne deux accès mémoires sont exécutés dans chaque warp en même temps, la concurrence d'instruction recherchée de 32 instructions d'accès mémoire par SM peut être atteinte en utilisant 16 warps par SM.*



Illustration : masquer la latence «*latency hiding*»

```
x = a + b; // prends ~20 cycles pour s'exécuter
y = a + c; // indépendante, peut démarrer n'importe quand
bloqué
z = x + d; // dépendante, doit attendre x
```

**Latence** : temps requis pour réaliser une opération :

- 20 cycles pour une opération arithmétique, 400 cycles pour une opération mémoire ;
- on ne peut pas démarrer une instruction **avec une dépendance** pour masquer ce temps d'attente ;
- on ne peut pas **masquer** cette latence en la **recouvrant** avec une autre opération ;

**Latence ≠ débit** :


les opérations arithmétiques sont 20x plus rapides que les opérations mémoires...

mais l'un est un temps d'attente et l'autre un débit

Le **débit** est le nombre d'opérations que l'on peut finir par cycle

- **arithmétique** : 1,3Tflop/s = 480 ops/cycle avec une opération MAD, «*multiply-add*» ;
- **mémoire** : 177GB/s = 32 ops/cycle avec une opération d'échange sur 32bits.

## Comment cacher la latence ? Comment atteindre le débit de crête ?



$$\text{Needed parallelism} = \text{Latency} \times \text{Throughput}$$


Augmenter le **nombre d'opérations programmables** par le **scheduler** du GPU :

GPU model	Latency (cycles)	Throughput (cores/SM)	Parallelism (operations/SM)
G80-GT200	≈24	8	≈192
GF100	≈18	32	≈576
GF104	≈18	48	≈864


En utilisant le TLP, «*Thread Level Parallelism*» et l'ILP, «*Instruction Level Parallelism*» .



Thread Level Parallelism : augmenter le nombre de threads



Instruction Level Parallelism : augmenter le nombre d'instructions par thread



ILP=1

```
#pragma unroll UNROLL
for(int i=0; i<N; i++ )
{
    a = a * b + c;
}
```

ILP=2

```
#pragma unroll UNROLL
for(int i=0; i<N; i++ )
{
    a = a * b + c;
    d = d * b + c;
}
```

ILP=3

```
#pragma unroll UNROLL
for( int i = 0; i < N_ITERATIONS; i++ )
{
    a = a * b + c;
    d = d * b + c;
    e = e * b + c;
}
```

### Observations

- Si une opérande n'est pas prête, alors le warp est bloqué.
- Quand un warp est **bloqué**, on effectue un **changement de contexte** vers un warp capable de s'exécuter.
- Les **registres** et la **mémoire partagée** sont alloués par bloc aussi longtemps que le bloc est **actif**.
- Quant un **bloc** est **actif**, il reste **actif** tant que toutes les threads du bloc ne sont pas **terminées**.
- Le changement de contexte est **très rapide** parce que les registres et la mémoire partagée ne doivent être **ni sauvegardés ni restaurés**.

**But** : avoir suffisamment de transaction en vol pour saturer le bus de mémoire :


- ▷ la latence peut être **masquée** en ayant plus de transaction en vol ;
- ▷ **augmenter** le nombre de **threads actives** ou le parallélisme niveau instruction, ILP, «*Instruction Level Parallelism*»

### Règles

- ▷ Plus le nombre d'ILP ↗ moins il faut de threads pour atteindre la puissance de crête, «peak» ;
- ▷ Plus le nombre de threads ↘ :
  - ◊ plus on dispose de registres par threads ;
  - ◊ plus l'**occupancy** ↘ ;
- ▷ le registre est la mémoire la plus rapide disponible, plus rapide que la mémoire partagée ;  
*les variables locales à un kernel sont allouées sous forme de registres*
- ▷ plus l'**occupancy**, liée au TLP, ↘ plus les performances dépendent de l'ILP ;



Exemple :



- ▷ deux types d'instructions : arithmétique et accès mémoire ;
- ▷ chaque warp alterne entre accès mémoire et opération arithmétique : moitié du temps pour l'une et moitié du temps pour l'autre ;
- ▷ avec 3 warps : le nombre d'opérations arithmétique est de 1,5 en moyenne, et le nombre d'accès mémoire est également de 1,5 ;

Si on recherche également la concurrence de 32 accès mémoire pour atteindre le **débit de crête**, on a besoin de 64 warps exécutés en même temps.

Sur le transparent précédent, on avait juste besoin de 16 warps avec l'**ILP**.

On améliore encore en utilisant plus de type d'instruction : SFU, FP, accès mémoire global, accès mémoire partagée.

## «Warp latency» et «throughput»

On considère les warps comme élément dans le **loi de Little** :

- ▷ **latence** : différence entre les temps de début et de fin d'un warp ;
- ▷ **concurrence** : nombre de warps exécutés en même temps ⇒ **Occupancy** !
- ▷ **débit** : nombre de warps exécutés divisé par le temps total d'exécution.

$$\text{occupancy moyenne} = \text{warp latency moyenne} * \text{débit de warp}$$



## Exemple d'ILP : on «déroule le kernel»

71

```
#define N_ITERATIONS 8192
#define BLOCKSIZE 512
```

```
__global__ void kernel0(float *d_a, float *d_b, float *d_c, int N) {
    int tid = threadIdx.x + blockIdx.x * blockDim.x;
    if (tid < N) {
        float a = d_a[tid];
        float b = d_b[tid];
        float c = d_c[tid];
        for (unsigned int i = 0; i < N_ITERATIONS; i++) {
            a = a * b + c;
        }
        d_a[tid] = a;
    }
}
kernel0 <<<iDivUp(N, BLOCKSIZE), BLOCKSIZE >>>(d_a, d_b, d_c, N);
```

```
__global__ void kernel1(float *d_a, float *d_b, float *d_c, int N) {
    int tid = threadIdx.x + blockIdx.x * blockDim.x;
    if (tid < N / 2) {
        float a1 = d_a[tid];
        float b1 = d_b[tid];
        float c1 = d_c[tid];

        float a2 = d_a[tid + N / 2];
        float b2 = d_b[tid + N / 2];
        float c2 = d_c[tid + N / 2];

        for (unsigned int i = 0; i < N_ITERATIONS; i++) {
            a1 = a1 * b1 + c1;
            a2 = a2 * b2 + c2;
        }
        d_a[tid] = a1;
        d_a[tid + N / 2] = a2;
    }
}
kernel1 <<<iDivUp(N / 2, BLOCKSIZE), BLOCKSIZE >>>(d_a, d_b, d_c, N);
```



## Exemple d'ILP : on «déroule le kernel»

72

```
global__ void kernel2(float *d_a, float *d_b, float *d_c, int N) {
    int tid = threadIdx.x + blockIdx.x * blockDim.x;

    if (tid < N / 4) {
        float a1 = d_a[tid];
        float b1 = d_b[tid];
        float c1 = d_c[tid];

        float a2 = d_a[tid + N / 4];
        float b2 = d_b[tid + N / 4];
        float c2 = d_c[tid + N / 4];

        float a3 = d_a[tid + N / 2];
        float b3 = d_b[tid + N / 2];
        float c3 = d_c[tid + N / 2];

        float a4 = d_a[tid + 3 * N / 4];
        float b4 = d_b[tid + 3 * N / 4];
        float c4 = d_c[tid + 3 * N / 4];

        for (unsigned int i = 0; i < N_ITERATIONS; i++) {
            a1 = a1 * b1 + c1;
            a2 = a2 * b2 + c2;
            a3 = a3 * b3 + c3;
            a4 = a4 * b4 + c4;
        }
        d_a[tid] = a1;
        d_a[tid + N / 4] = a2;
        d_a[tid + N / 2] = a3;
        d_a[tid + 3 * N / 4] = a4;
    }
}
kernel2 <<<iDivUp(N / 4, BLOCKSIZE), BLOCKSIZE >>>(d_a, d_b, d_c, N);
```



# Exemple d'ILP : on «déroule le kernel»

73

Variable	Achieved	Theoretical	Device Limit	Grid Size: [ 16,1,1 ] (16 blocks) Block Size: [ 512,1,1 ] (512 threads)
Occupancy Per SM				
Active Blocks		4	32	
Active Warps	26.69	64	64	
Active Threads	2048	2048		
Occupancy	41.7%	100%	100%	
Warps				
Threads/Block		512	1024	
Warps/Block		16	32	
Block Limit		4	32	
Registers				
Registers/Thread		12	65536	
Registers/Block		8192	65536	
Block Limit		8	32	
Shared Memory				
Shared Memory/Block		0	98304	
Block Limit		0	32	

Variable	Achieved	Theoretical	Device Limit	Grid Size: [ 8,1,1 ] (8 blocks) Block Size: [ 512,1,1 ] (512 threads)
Occupancy Per SM				
Active Blocks		4	32	
Active Warps	15.97	64	64	
Active Threads		2048	2048	
Occupancy	25%	100%	100%	
Warps				
Threads/Block		512	1024	
Warps/Block		16	32	
Block Limit		4	32	
Registers				
Registers/Thread		20	65536	
Registers/Block		12288	65536	
Block Limit		5	32	
Shared Memory				
Shared Memory/Block		0	98304	
Block Limit		0	32	

Variable	Achieved	Theoretical	Device Limit	Grid Size: [ 4,1,1 ] (4 blocks) Block Size: [ 512,1,1 ] (512 threads)
Occupancy Per SM				
Active Blocks		4	32	
Active Warps	15.85	64	64	
Active Threads		2048	2048	
Occupancy	24.8%	100%	100%	
Warps				
Threads/Block		512	1024	
Warps/Block		16	32	
Block Limit		4	32	
Registers				
Registers/Thread		30	65536	
Registers/Block		16384	65536	
Block Limit		4	32	
Shared Memory				
Shared Memory/Block		0	98304	
Block Limit		0	32	



# Exemple d'ILP : l'architecture

74

[0] NVIDIA GeForce GTX 1060 6GB

GPU UUID	GPU-1cb95576-2e2c-d5c0-57dc-4c74d3e326e5
Compute Capability	6.1
Max. Threads per Block	1024
Max. Threads per Multiprocessor	2048
Max. Shared Memory per Block	48 KiB
Max. Shared Memory per Multiprocessor	96 KiB
Max. Registers per Block	65536
Max. Registers per Multiprocessor	65536
Max. Grid Dimensions	[ 2147483647, 65535, 65535 ]
Max. Block Dimensions	[ 1024, 1024, 64 ]
Max. Warps per Multiprocessor	64
Max. Blocks per Multiprocessor	32
Half Precision FLOP/s	36.7 GigaFLOP/s
Single Precision FLOP/s	4.698 TeraFLOP/s
Double Precision FLOP/s	146.8 GigaFLOP/s
Number of Multiprocessors	10
Multiprocessor Clock Rate	1.835 GHz
Concurrent Kernel	true
Max IPC	6
Threads per Warp	32
Global Memory Bandwidth	192.192 GB/s
Global Memory Size	5.934 GiB
Constant Memory Size	64 KiB
L2 Cache Size	1.5 MiB
Memcpy Engines	2
PCIe Generation	3
PCIe Link Rate	8 Gbit/s
PCIe Link Width	16



## Exemple d'ILP : les résultats

75

### kernel0(float\*, float const \*, float const \*, int)

Duration	45.738 $\mu$ s
Grid Size	[ 16,1,1 ]
Block Size	[ 512,1,1 ]
Registers/Thread	12
Shared Memory/Block	0 B
Shared Memory Executed	0 B
Shared Memory Bank Size	4 B

### kernel1(float\*, float const \*, float const \*, int)

Duration	44.311 $\mu$ s
Grid Size	[ 8,1,1 ]
Block Size	[ 512,1,1 ]
Registers/Thread	20
Shared Memory/Block	0 B
Shared Memory Executed	0 B
Shared Memory Bank Size	4 B

### kernel2(float\*, float const \*, float const \*, int)

Duration	85.825 $\mu$ s
Grid Size	[ 4,1,1 ]
Block Size	[ 512,1,1 ]
Registers/Thread	30
Shared Memory/Block	0 B
Shared Memory Executed	0 B
Shared Memory Bank Size	4 B



# Exemple d'ILP : les résultats

76



# ILP : est-ce automatique ?

77

```
__global__ void testKernel1(float* input, float* output, int N) {
    int tid = threadIdx.x + blockIdx.x * blockDim.x;

    if (tid < N) {
        float accum = 0.f;

        for (int i = 0; i < 8; i++) {
            accum = accum + input[n_loop*tid+i];
        }
        output[tid] = accum;
    }
}
```

```
mov.u32 %r3, %ntid.x;
mov.u32 %r4, %ctaid.x;
mov.u32 %r5, %tid.x;
mad.lo.s32 %r1, %r3, %r4, %r5;
setp.ge.s32    %p1, %r1, %r2;
@%p1 bra BB0_2;

cvta.to.global.u64 %rd1, %rd1;
cvta.to.global.u64 %rd2, %rd2;
shl.b32 %r6, %r1, 3;
mul.wide.s32 %rd5, %r6, 4;
add.s64 %rd6, %rd3, %rd5;
ld.global.f32 %f1, [%rd6];
add.f32 %f2, %f1, 0f00000000;
ld.global.f32 %f3, [%rd6+4];
add.f32 %f4, %f2, %f3;
ld.global.f32 %f5, [%rd6+8];
add.f32 %f6, %f4, %f5;
ld.global.f32 %f7, [%rd6+12];
add.f32 %f8, %f6, %f7;
ld.global.f32 %f9, [%rd6+16];
add.f32 %f10, %f8, %f9;
ld.global.f32 %f11, [%rd6+20];
add.f32 %f12, %f10, %f11;
ld.global.f32 %f13, [%rd6+24];
add.f32 %f14, %f12, %f13;
ld.global.f32 %f15, [%rd6+28];
add.f32 %f16, %f14, %f15;
mul.wide.s32 %rd7, %r1, 4;
add.s64 %rd8, %rd4, %rd7;
st.global.f32 [%rd8], %f16;

BB0_2:
ret;
}
```

On peut également utiliser la directive de compilateur :

```
#pragma unroll N
```

*Cette directive du compilateur «déroule» la boucle en écrivant le code des différentes instances de la boucle en série ⇒ créer des instructions capables de s'exécuter en parallèle.*

⇒ la boucle for n'existe plus... 8 Load... ⇒ le compilateur a déroulé le code !



# ILP : est-ce automatique ?

78


```
sudo nvprof --metrics unique_warps_launched,sm_efficiency,achieved_occupancy,ipc,issued_ipc,is  
sue_slot_utilization ./demo2_ilp  
==124261== NVPROF is profiling process 124261, command: ./demo2_ilp  
==124261== Profiling application: ./demo2_ilp  
==124261== Profiling result:  
==124261== Metric result:  


| Metric Name                                   | Metric Description       | Min      | Max      | Avg      |
|-----------------------------------------------|--------------------------|----------|----------|----------|
| Device "NVIDIA GeForce GTX 1060 6GB (0)"      |                          |          |          |          |
| Kernel: testKernel1(float*, float*, int)      |                          |          |          |          |
| unique_warps_launched                         | Number of warps launched | 262144   | 262144   | 262144   |
| sm_efficiency                                 | Multiprocessor Activity  | 99.86%   | 99.86%   | 99.86%   |
| achieved_occupancy                            | Achieved Occupancy       | 0.755754 | 0.755754 | 0.755754 |
| ipc                                           | Executed IPC             | 0.203224 | 0.203224 | 0.203224 |
| issued_ipc                                    | Issued IPC               | 0.203273 | 0.203273 | 0.203273 |
| issue_slot_utilization                        | Issue Slot Utilization   | 4.81%    | 4.81%    | 4.81%    |
| Kernel: testKernel2(float*, float*, int)      |                          |          |          |          |
| unique_warps_launched                         | Number of warps launched | 262144   | 262144   | 262144   |
| sm_efficiency                                 | Multiprocessor Activity  | 99.92%   | 99.92%   | 99.92%   |
| achieved_occupancy                            | Achieved Occupancy       | 0.750792 | 0.750792 | 0.750792 |
| ipc                                           | Executed IPC             | 0.252322 | 0.252322 | 0.252322 |
| issued_ipc                                    | Issued IPC               | 0.252369 | 0.252369 | 0.252369 |
| issue_slot_utilization                        | Issue Slot Utilization   | 6.31%    | 6.31%    | 6.31%    |
| Kernel: testKernel3(float*, float*, int, int) |                          |          |          |          |
| unique_warps_launched                         | Number of warps launched | 262144   | 262144   | 262144   |
| sm_efficiency                                 | Multiprocessor Activity  | 99.90%   | 99.90%   | 99.90%   |
| achieved_occupancy                            | Achieved Occupancy       | 0.760726 | 0.760726 | 0.760726 |
| ipc                                           | Executed IPC             | 0.361742 | 0.361742 | 0.361742 |
| issued_ipc                                    | Issued IPC               | 0.361795 | 0.361795 | 0.361795 |
| issue_slot_utilization                        | Issue Slot Utilization   | 8.36%    | 8.36%    | 8.36%    |
| Kernel: testKernel4(float*, float*, int, int) |                          |          |          |          |
| unique_warps_launched                         | Number of warps launched | 262144   | 262144   | 262144   |
| sm_efficiency                                 | Multiprocessor Activity  | 99.90%   | 99.90%   | 99.90%   |
| achieved_occupancy                            | Achieved Occupancy       | 0.796014 | 0.796014 | 0.796014 |
| ipc                                           | Executed IPC             | 0.587706 | 0.587706 | 0.587706 |
| issued_ipc                                    | Issued IPC               | 0.587767 | 0.587767 | 0.587767 |
| issue_slot_utilization                        | Issue Slot Utilization   | 13.08%   | 13.08%   | 13.08%   |


```



- ▷ «*Warp Scheduler*» : gère les warps, sélectionne celles prêtes à être exécutées ;
- ▷ «*Fetch/Decode Unit*» : est associé à un «*warp scheduler*» ;
- ▷ «*Execution Units*» : [SC, SFU, LD/ST] ;



Faire de l'ILP entre EU de **nature différentes** :

- SFU : «*Special Function Unit*» : fonctions transcendentales *cos*, *sin*, *expf*, etc.
- LD/ST : «*Load*» et «*Store*» : lit et écrit dans la mémoire ;
- SC : les instructions arithmétique et logiques.

*Chaque EU peut travailler en même temps qu'une autre EU de nature différente.*

**Dessiner un ensemble de Julia**

On parcourt une surface 2D :

- \* pour chaque point de coordonnées  $(x, y)$ , on traduit ses coordonnées dans l'espace complexe :
  - ◊ Soit  $DIM \times DIM$  la dimension de la surface en pixels ;
  - ◊ on centre cet espace complexe au centre de l'image, en décalant de  $DIM/2$  ;
  - ◊ ce qui donne pour un point  $(x, y)$ , les coordonnées

$$((DIM/2 - x)/(DIM/2), (DIM/2 - y)/(DIM/2))$$

- \* on utilise également un «zoom» avec la variable *scale* pour zoomer ou dézoomer sur l'ensemble de Julia ;
- \* la constante  $C = -0.8 + 1.5i$  donne une image intéressante.
- \* on considère le complexe  $Z_0 = ((DIM/2 - x)/(DIM/2)) + ((DIM/2 - y)/(DIM/2))i$
- \* on calcule alors pour ce complexe  $Z_0$ , la limite de la suite  $Z_{n+1} = Z_n^2 + C$ :
  - ◊ si la limite de la suite diverge ou tend vers l'infini, alors le point n'appartient pas à l'ensemble et il sera coloré en noir ;
  - ◊ si la limite de la suite ne diverge pas, alors le point fait partie de l'ensemble et sera coloré en rouge.
- \* pour la limite, on utilise une simplification : si après 200 itérations de calcul de la suite, la valeur au carré de la suite est toujours inférieure à 1000 alors on considère qu'elle ne diverge pas.



# Un exemple complet

81

## Version CPU

```
int main( void ) {
    CPUBitmap bitmap( DIM, DIM ); // DIM = 1000
    unsigned char *ptr = bitmap.get_ptr();
    kernel( ptr );
    bitmap.display_and_exit();
}
```

```
int julia( int x, int y ) {
    const float scale = 1.5;
    float jx = scale * (float)(DIM/2 - x)/(DIM/2);
    float jy = scale * (float)(DIM/2 - y)/(DIM/2);

    cuComplex c(-0.8, 0.156);
    cuComplex a(jx, jy);
    int i = 0;
    for (i=0; i<200; i++) { // Calcul de la limite
        a = a * a + c;
        if (a.magnitude2() > 1000) // Infini ?
            return 0; // Pas dans l'ensemble
    }
    return 1; // Dans l'ensemble
}
```

```
void kernel( unsigned char *ptr ) {
    for (int y=0; y<DIM; y++) {
        for (int x=0; x<DIM; x++) {
            int offset = x + y * DIM; // 2D -> 1D

            int juliaValue = julia( x, y );
            ptr[offset*4 + 0] = 255 * juliaValue; // Red
            ptr[offset*4 + 1] = 0; // Green
            ptr[offset*4 + 2] = 0; // Blue
            ptr[offset*4 + 3] = 255; } // Alpha
    }
}
```

```
struct cuComplex { // Opérations sur les complexes
    float r, i;

    cuComplex( float a, float b ) : r(a), i(b) {}

    float magnitude2(void) { return r * r + i * i; }

    cuComplex operator*(const cuComplex& a) {
        return cuComplex(r*a.r-i*a.i, i*a.r+r*a.i);
    }
    cuComplex operator+(const cuComplex& a) {
        return cuComplex(r+a.r, i+a.i);
    }
};
```



## Un exemple complet

82

### Version GPU


```
int main( void ) {
    CPUBitmap bitmap( DIM, DIM );
    unsigned char *dev_bitmap;
    HANDLE_ERROR( cudaMalloc( (void**)&dev_bitmap, bitmap.image_size() ) ); // On alloue la zone de l'image
    dim3 grid(DIM,DIM); // On utilise dim3 même si la dernière coordonnée vaudra seulement 1
    kernel<<<grid,1>>>( dev_bitmap ); // Un bloc par pixel et une thread par bloc
    HANDLE_ERROR( cudaMemcpy( bitmap.get_ptr(), dev_bitmap, bitmap.image_size(),
                           cudaMemcpyDeviceToHost ) );
    bitmap.display_and_exit();
    cudaFree( dev_bitmap );
}

__global__ void kernel( unsigned char *ptr ) {
    // map from threadIdx/BlockIdx to pixel position
    int x = blockIdx.x; // Calculé automatiquement
    int y = blockIdx.y; // Calculé automatiquement
    int offset = x + y * gridDim.x;
    // now calculate the value at that position
    int juliaValue = julia( x, y );
    ptr[offset*4 + 0] = 255 * juliaValue;
    ptr[offset*4 + 1] = 0;
    ptr[offset*4 + 2] = 0;
    ptr[offset*4 + 3] = 255;
}

__device__ int julia( int x, int y ) {
    const float scale = 1.5;
    float jx = scale * (float)(DIM/2 - x)/(DIM/2);
    float jy = scale * (float)(DIM/2 - y)/(DIM/2);
    cuComplex c(-0.8, 0.156);
    cuComplex a(jx, jy);
    int i = 0;
    for (i=0; i<200; i++) {
        a = a * a + c;
        if (a.magnitude2() > 1000)
            return 0;
    }
    return 1;
}
```



```
struct cuComplex {  
    float r, i;  
    cuComplex( float a, float b ) : r(a), i(b) {}  
    __device__ float magnitude2( void )  
    {  
        return r * r + i * i;  
    }  
    __device__ cuComplex operator*(const cuComplex& a)  
    {  
        return cuComplex(r*a.r - i*a.i, i*a.r + r*a.i);  
    }  
    __device__ cuComplex operator+(const cuComplex& a)  
    {  
        return cuComplex(r+a.r, i+a.i);  
    }  
};
```



Les fonctions préfixées par `__device__`:

- ◊ tournent sur le GPU;
- ◊ ne peuvent être appelées que depuis une fonction préfixée par `__device__` ou `__global__`.

Le code complet est accessible sur <http://developer.nvidia.com/cuda-cc-sdk-code-samples>

## Parcours imbriqué d'un tableau en version CPU

```
void add_matrix ( float* a, float* b, float* c, int N )
{
    int index;
    for ( int i = 0; i < N; ++i )
        for ( int j = 0; j < N; ++j ) {
            index = i + j*N;
            c[index] = a[index] + b[index];
        }
}
int main() {
    add_matrix( a, b, c, N );
}
```

Ici, la matrice est définie suivant un tableau à une seule dimension.

## Parcours imbriqué d'un tableau en version GPU

```
__global__ add_matrix ( float* a, float* b, float* c,
int N )
{
    int i = blockIdx.x * blockDim.x + threadIdx.x;
    int j = blockIdx.y * blockDim.y + threadIdx.y;
    int index = i + j*N;
    if ( i < N && j < N )
        c[index] = a[index] + b[index];
}
int main() {
    dim3 dimBlock( blocksize, blocksize );
    dim3 dimGrid( N/dimBlock.x, N/dimBlock.y );
    add_matrix<<<dimGrid, dimBlock>>>( a, b, c, N );
}
```

On «déplie» les deux boucles imbriquées en une grille, où chaque élément de la grille définit une combinaison de valeurs pour  $i$  et  $j$ .



```
const int N = 1024;
const int blocksize = 16;
__global__ void add_matrix( float* a, float *b, float *c, int N )
{
    int i = blockIdx.x * blockDim.x + threadIdx.x;
    int j = blockIdx.y * blockDim.y + threadIdx.y;
    int index = i + j*N;
    if ( (i < N) && (j < N) ) c[index] = a[index] + b[index];
}

int main() {
    float *a = new float[N*N]; float *b = new float[N*N]; float *c = new float[N*N];
    for ( int i = 0; i < N*N; ++i ) { a[i] = 1.0f; b[i] = 3.5f; }
    float *ad, *bd, *cd;
    const int size = N*N*sizeof(float);
    cudaMalloc( (void**)&ad, size );
    cudaMalloc( (void**)&bd, size );
    cudaMalloc( (void**)&cd, size );

    cudaMemcpy( ad, a, size, cudaMemcpyHostToDevice );
    cudaMemcpy( bd, b, size, cudaMemcpyHostToDevice );

    dim3 dimBlock( blocksize, blocksize );
    dim3 dimGrid( N/dimBlock.x, N/dimBlock.y );
    add_matrix<<<dimGrid, dimBlock>>>( ad, bd, cd, N );

    cudaMemcpy( c, cd, size, cudaMemcpyDeviceToHost );

    cudaFree( ad ); cudaFree( bd ); cudaFree( cd );
    delete[] a; delete[] b; delete[] c;

    return EXIT_SUCCESS;
}
```



## Les contraintes d'architecture

- ▷ un GPU possède  $N$  multiprocesseur,  $MP$ , en général 2 ou 4 ;
- ▷ chaque MP possède  $M$  processeur scalaire,  $SP$  ;
- ▷ chaque MP traite des blocks par lot :
  - ◊ un bloc est traité par un MP uniquement ;
- ▷ chaque bloc est découpé en groupe de threads SIMD appelé warp :
  - ◊ un warp est exécuté physiquement en parallèle ;
- ▷ le scheduler « switche » entre les warps ;
- ▷ un warp contient des threads d'identifiant consécutifs, «thread ID» ;
- ▷ la taille d'un warp est actuellement de 32 ;

## Les optimisations possibles

- ▷  $\frac{\text{nombre de blocks}}{\text{nombre de MP}} > 1 \Rightarrow$  tous les MPs ont toujours quelque chose à faire ;
- ▷  $\frac{\text{nombre de blocks}}{\text{nombre de MP}} > 2 \Rightarrow$  plusieurs blocs peuvent être exécutés en parallèle sur un MP ;
- ▷ les ressources par block  $\leq$  au total des ressources disponibles :
  - ◊ mémoire partagée et registres ;
  - ◊ plusieurs blocs peuvent être exécutés en parallèle sur un MP ;
  - ◊ éviter les **branchements divergents** dans les conditions à l'intérieur d'un bloc :
    - \* les différents chemins d'exécution doivent être **sérialisés** !



## Une grille 1D avec des blocs en 2D

```
UniqueBlockIndex = blockIdx.x;  
UniqueThreadIndex = blockIdx.x * blockDim.x * blockDim.y + threadIdx.y * blockDim.x + threadIdx.x;
```

## Une grille 1D avec des blocs en 3D

```
UniqueBlockIndex = blockIdx.x;  
UniqueThreadIndex = blockIdx.x * blockDim.x * blockDim.y * blockDim.z  
+ threadIdx.z * blockDim.y * blockDim.x + threadIdx.y * blockDim.x + threadIdx.x;
```

## Une grille 2D avec des blocs 1D

```
UniqueBlockIndex = blockIdx.y * gridDim.x + blockIdx.x;  
UniqueThreadIndex = UniqueBlockIndex * blockDim.x + threadIdx.x;
```

## Un grille 2D avec des blocs 2D


```
UniqueBlockIndex = blockIdx.y * gridDim.x + blockIdx.x;  
UniqueThreadIndex = UniqueBlockIndex * blockDim.y * blockDim.x + threadIdx.y * blockDim.x + threadIdx.x;
```

## Une grille 2D avec des blocs 3D

```
UniqueBlockIndex = blockIdx.y * gridDim.x + blockIdx.x;  
UniqueThreadIndex = UniqueBlockIndex * blockDim.z * blockDim.y * blockDim.x  
+ threadIdx.z * blockDim.y * blockDim.x + threadIdx.y * blockDim.x + threadIdx.x;
```



- «*GigaThread global scheduler*» :
  - ◊ distribue les blocs de threads aux SMs ;
  - ◊ gère le changement de contexte entre les threads pendant l'exécution ;
- DRAM : jusqu'à 6GB de mémoire grâce à un adressage sur 64bits, débit de 192GB/s ;
- Fréquence processeur : 1,5GHz, Peak performance : 1,5TFlops, Fréquence mémoire : 2GHz ;



- un «*core*» CUDA :
  - ◊ une ALU, «*Integer Arithmetic Logic Unit*» : supporte des opérations sur 32bits, peut également travailler sur 64bits ;
  - ◊ FPU, «*Floating Point Unit*» : réalise des «*Fused Multiply-Add*»,  $A * B + C$ , jusqu'à 16 opérations en double précision par SM et par cycle ;
- LoaD/STore : calcule les adresses sources et destinations pour 16 threads par cycle d'horloge depuis/vers la DRAM ou le cache ;
- SM, «*Streaming Multi-processors*» contient :
  - ◊ 32 cœurs «*single precision*» ;
  - ◊ 4 unités SFUs, «*Special Function Units*» :
    - \* fonctions transcendentales sinus/cosinus, inverse et racine carrée ;
    - \* une instruction par thread et par cycle d'horloge : un «*warp*» exécute l'opération en 8 cycles ;
  - ◊ un bloc de 64KB de mémoire rapide : mémoire cache L1
  - ◊ 32k of 32 bits registers :
    - \* chaque thread possède ses propres registres entre 21 et 63 (l'augmentation du nombre de threads diminue le nombre de registres par threads) ;
    - \* la vitesse d'échange de ces registres est de 8GB/s ;
  - ◊ Warp scheduler : ordonnancement des warps de 32 threads ;



512 «*cuda cores*» organisés en 16 SM de 32 cores chacun.

32 «*cuda cores*» par SM, «*Streaming Multiprocessor*».


Un «*cuda core*» correspond à un circuit capable de réaliser un calcul en simple précision, FPU, ou sur un entier, ALU (opérations binaire comprises), en 1 cycle d'horloge.

Une unité «*Special Function Unit*» exécute les opérations transcendentales comme le *sin*, *cos*, *sqrt*, *arccos*, etc.

*Il en existe 4 : seuls 4 opérations de ce type peuvent avoir lieu simultanément.*

Le GPU dispose de 6 partition mémoire de 64 bits, soient 16 unités sur 32bits.


16 unités «*Load/Store*» permettent d'accéder en écriture ou en lecture à des données pour 16 threads par cycle d'horloge.



Deux «*Warp Schedulers*» permettent de programmer l'exécution de deux Warps indépendants simultanément :

- seuls les warps capables de s'exécuter peuvent être exécutés simultanément ;
- un scheduler programme l'exécution d'une instruction d'un Warp vers un groupe de 16 cores/16 LD/ST or 4 SFUs.
- la plupart des instructions peuvent être émises par deux : deux instructions entières, deux instructions flottantes, un mix d'entier de flottant, lecture, écriture et opération transcendentale.

**Mais les instructions en double précision ne peuvent pas être émises par deux.**



## Des opérations spéciales

MAD, «*multiply-add*» : une opération de multiplication et d'addition combinée, mais avec perte des bits dépassant la capacité.

FMA, «*fused multiply-add*» : réalise les mêmes opérations mais sans perte, en simple ou double précision.

L'utilisation de calcul en double précision permet 16 calcul de type MAD par SM et par cycle d'horloge.

## La mémoire

- cache L1/mémoire partagée, utilisable au choix :
    - ◊ en mémoire partagée entre les threads pour leur permettre de coopérer en échangeant des données ;
    - ◊ pour conserver la valeur des registres nécessaires à une thread qui ne peuvent être affectées à des registres disponibles dans le SM. *On parle de «spilled» registers*, c-à-d du débordement de registres ;
    - ◊ débit : 1600Go/s ;
    - ◊ organisable en 16Ko de cache L1 et 48Ko de mémoire partagée ou 48Ko de cache L1 ;
    - ◊ organisable en 48Ko de cache L1 et 16Ko de mémoire partagée ou 48Ko de cache L1 ;
  - cache L2 : 768Ko partagé entre les 16 SMs qui sert aux :
    - ◊ accès vers/depuis la mémoire globale ;
    - ◊ copies depuis/vers le Host ;
    - ◊ accès aux textures.

### Multiply-Add (MAD):

$$\begin{array}{r} \textbf{A} \quad \times \quad \textbf{B} \quad = \quad \textbf{Product} \quad (\text{truncate extra digits}) \\ \qquad \qquad \qquad \qquad \qquad + \\ \qquad \qquad \qquad \qquad \qquad \boxed{\textbf{C}} \quad = \quad \textbf{Result} \end{array}$$

## Fused Multiply-Add (FMA)

A	×	B	=	Product	(retain all digits)	
				+		
				C	=	Result

